Viacjazyčné a medzijazykové vyhľadávanie overených tvrdení

SemEval-2025 Task 7 – 1. etapa: návrh projektu a baseline riešenie

Viktor Hančovský, Benjamín Konkoľ, Jakub Spišák, Roman Šafranko

25. októbra 2026

Abstrakt

Zaoberáme sa úlohou SemEval-2025 Task 7: pre príspevok zo sociálnej siete treba v kolekcii stoviek tisíc už overených tvrdení (fact-checkov) nájsť tie, ktoré sa ho týkajú, a to aj vtedy, keď sú príspevok a fact-check v rôznych jazykoch. V prvej etape sme implementovali reprodukovateľný experimentálny rámec s oficiálnym protokolom hodnotenia a dve baseline riešenia: lexikálne BM25 a husté vyhľadávanie pomocou modelu multilingual-E5-large bez dotrénovania. Na testovacej množine dosahuje náš E5 baseline S@10 0,886 (monolingválna úloha) a 0,681 (medzijazyková úloha). Naše E5 prekonáva E5 baseline organizátorov v oboch podúlohách (0,859 a 0,637); v medzijazykovej úlohe však zaostáva za ich GTR-T5-Large baseline (0,705). Upravené BM25 so stemovaním, odstraňovaním stop slov a segmentáciou thajčiny dosahuje 0,868 a 0,623.

1 Úvod

Problém. Dezinformácie sa šíria rýchlejšie, než ich stihnú profesionálni overovatelia faktov (fact-checkeri) vyvracať. Veľká časť nepravdivých tvrdení sa však opakuje: to isté tvrdenie sa objavuje v nových príspevkoch, v iných formuláciách, na iných platformách a často aj v iných jazykoch. Ak by overovateľ vedel pre nový príspevok rýchlo nájsť už existujúci fact-check, nemusí tvrdenie overovať znova. Takáto úloha sa nazýva *vyhľadávanie už overených tvrdení* (previously fact-checked claim retrieval) [19].

Formulácia úlohy. Pre príspevok p zo sociálnej siete (text, prípadne text extrahovaný z priložených obrázkov pomocou OCR) a kolekciu fact-checkov $\mathcal{F}$ má systém vrátiť usporiadaný zoznam fact-checkov tak, aby sa relevantné fact-checky nachádzali čo najvyššie. Ide o úlohu *vyhľadávania a usporiadania* (ranking), nie o klasifikáciu pravdivosti. Úloha SemEval-2025 Task 7 [11] má dve podúlohy:

- **monolingválnu** — príspevok aj fact-check sú v rovnakom jazyku a kolekcia kandidátov je obmedzená na fact-checky v jazyku príspevku,
- **medzijazykovú** (crosslingual) — príspevok a fact-check môžu byť v rôznych jazykoch a kolekcia kandidátov nie je obmedzená.

Motivácia. Fact-checky existujú prevažne vo veľkých jazykoch (najmä v angličtine), zatiaľ čo dezinformácie sa šíria vo všetkých jazykoch. Medzijazykové vyhľadávanie umožňuje znovu využiť existujúcu prácu overovateľov aj v jazykoch, kde je ich málo [11, 14].

Ciele projektu.

1. Vytvoriť reprodukovateľný experimentálny rámec s oficiálnym protokolom hodnotenia (1. etapa).

2. Implementovať a vyhodnotiť lexikálne a husté baseline riešenie (1. etapa).

3. Navrhnúť vlastné riešenie, ktoré baseline podstatne zlepší: fúziu výsledkov, dotrénovanie modelu na trénovacích pároch so ťažkými negatívnymi príkladmi a preusporiadanie kandidátov (2. etapa).

4. Systematicky analyzovať chyby a výsledky interpretovať po jazykoch (2. etapa).

Projekt sa zameriava primárne na monolingválnu podúlohu; medzijazykovú podúlohu vyhodnocujeme paralelne, keďže zdieľa celý systém aj predvypočítané reprezentácie.

2 Prehľad existujúcich prístupov

Vyhľadávanie už overených tvrdení. Shaar et al. [19] úlohu formulovali a použili dvojfázový prístup: kandidátov získali pomocou BM25 a preusporiadali ich modelom založeným na BERT s učením sa usporiadania (learning to rank). Vo and Lee [22] vyhľadávali fact-checkové články k tweetom s využitím textu aj obrázkov, čo je relevantné aj pre nás, keďže časť príspevkov obsahuje text iba v obrázku. Shaar et al. [20] ukázali, že kontext na strane vstupného tvrdenia v politickej debate môže zlepšiť vyhľadávanie o viac ako 10 bodov MAP; nejde o priamy experiment s OCR príspevkov zo sociálnych sietí. Kazemi et al. [6] rozšírili párovanie tvrdení na jazyky mimo angličtiny (hindčina, bengálčina, malajálamčina, tamilčina) pomocou destilovaného viacjazyčného modelu viet. Pikuliak et al. [14] vytvorili dátovú množinu MultiClaim (približne 28 tis. príspevkov v 27 jazykoch a 206 tis. fact-checkov v 39 jazykoch), z ktorej vychádza aj táto úloha. Najlepším modelom bez dotrénovania bol v ich porovnaní GTR-T5-Large [9].

Reprezentácie textu pre vyhľadávanie. Klasickým lexikálnym modelom je BM25 [18]. Husté vyhľadávanie používa bi-enkodéry, ktoré zakódujú dotaz a dokument nezávisle do vektora a podobnosť počítajú ako kosínusovú podobnosť [16]. Viacjazyčné bi-enkodéry vznikajú destiláciou z jednojazyčných modelov [17] alebo kontrastívnym predtrénovaním na veľkých viacjazyčných korpusoch, napríklad modely E5 [23, 24] a BGE-M3 [1]. Presnejšie, ale pomalšie sú cross-enkodéry, ktoré spracujú dotaz aj dokument naraz a používajú sa na preusporiadanie malého počtu kandidátov [10]. Výsledky viacerých vyhľadávačov sa dajú kombinovať pomocou reciprocal rank fusion [3].

Riešenia v SemEval-2025 Task 7. Súťaže sa zúčastnilo 179 registrovaných účastníkov s 52 testovacími odovzdaniami [11]. Poradia a nasledujúce monolingválne skóre preberáme z oficiálneho prehľadu (tabuľka 8); články tímov môžu uvádzať iné zaokrúhlenie. Najlepší výsledok bol S@10 0,9601, desiate miesto 0,9232. Zdokumentované systémy často kombinujú husté vyhľadávanie s preusporiadaním alebo fúziou modelov, existujú však aj silné systémy bez týchto krokov.

- **TIFIN India** [4] (3. miesto, 0,9383): preklad príspevkov do angličtiny modelom Aya-expanse-8B, dotrénovanie Stella-400M s ťažkými negatívnymi príkladmi, preusporiadanie 50 kandidátov modelom Qwen2.5-72B a RRF. Samotný dotrénovaný vyhľadávač s prekladmi dosiahol 0,9217 (tabuľka 5 článku).

- **RACAI** [2] (4. miesto, 0,9377): BGE-Multilingual-Gemma2-9B na originálnych textoch, kontrastívne dotrénovaný pomocou LoRA, bez preusporiadania. Prompt tuning, QLoRA a Matryoshka reprezentácie skúmali samostatne; nemožno ich všetky pripísať finálnej konfigurácii.

- **QUST_NLP** [8] (5. miesto, 0,9365): výber vyhľadávačov podľa jazyka, preusporiadanie a vážené hlasovanie. V abláciách modelov E5 spojenie originálu s prekladom zlepšilo monolingválny priemer, zatiaľ čo v medzijazykovej úlohe bol lepší samotný preklad (§4.1, tabuľky 1–2 článku); nejde o pravidlo pre každý model a jazyk.

- **UniBuc-AE** [5] (6. miesto, 0,9336): anglický e5-large-v2 a viacjazyčný multilingual-e5-large-instruct, kontrastívne učenie a následné dotrénovanie s ťažkými negatívnymi príkladmi. Štyri konfigurácie kombinujú váženými skóre podobnosti, s váhami vybranými na validačných dátach.

- **UWBa** [7] (7. miesto, 0,9270): bez dotrénovania, nad anglickými prekladmi. Finálny monolingválny systém podľa jazyka vyberá NV-Embed-v2 samostatne alebo v dvojici s GPT či Mistral; medzijazykový systém používa iba NV-Embed. Päť modelov skúmali pri predbežnom výbere, nie vo finálnej spoločnej kombinácii.

- **fact check AI** [15] (10. miesto, 0,9232): dotrénované bi-enkodéry a kombinovanie modelov trénovaných v piatich foldoch. Monolingválne spracovanie využíva originály aj preklady, medzijazykové anglické preklady.

- **Duluth** [21]: finálny lexikálny systém TF-IDF so slovnou tokenizáciou a 15 000 príznakmi dosiahol 0,6883 (tabuľka 3 článku; zaokrúhlene 0,69).

Tieto výsledky motivujú samostatne overiť prínos dotrénovania, preusporiadania a fúzie na našej vývojovej množine; nezaručujú zlepšenie pre každú konfiguráciu. Výpočtové nároky publikovaných veľkých modelov nemožno preniesť na našu 8 GB GPU bez samostatného overenia; v 2. etape preto plánujeme menšie modely a dotrénovanie na vzdialenej GPU.

3 Dáta

Používame oficiálnu dátovú množinu úlohy [12], ktorá je dostupná na výskumné účely na základe žiadosti. Trénovacia a vývojová časť vychádza z MultiClaim [14]; testovacia časť obsahuje nové dáta zozbierané rovnakou metodikou.

Štruktúra. Každý *príspevok* obsahuje text napísaný používateľom a texty extrahované z priložených obrázkov (OCR, Google Vision API). Každý *fact-check* obsahuje overované tvrdenie (claim) a názov článku (title). Všetky texty sú dostupné v origináli aj v anglickom preklade (Google Translate) spolu s detegovaným jazykom. Rozdelenie na podúlohy, trénovacie, vývojové a testovacie príspevky aj kolekciu kandidátov pre každú podúlohu definuje súbor `tasks.json`. Monolingválna úloha má v trénovacej a vývojovej časti 8 jazykov (ara, deu, eng, fra, msa, por, spa, tha); testovacia časť pridáva poľštinu a turečtinu, ktoré neboli vopred ohlásené.

Pozorovania.

- **Veľkosti kolekcií sa líšia o tri rády**: od 382 (thajčina) po 145 287 (angličtina, test). Úloha je preto v rôznych jazykoch rôzne ťažká a priemerovanie cez jazyky dáva malým jazykom rovnakú váhu ako angličtine. Niektoré vývojové množiny sú veľmi malé (thajčina 42, arabčina 78 príspevkov), takže rozdiely v jednotlivých jazykoch na vývojovej množine treba interpretovať opatrne.

- **Približne 11–21 % príspevkov má viac správnych fact-checkov** (rovnaké tvrdenie overilo viacero organizácií), čo metriku S@10 mierne zvýhodňuje.

- **Text v obrázkoch je dôležitý**: takmer polovica príspevkov obsahuje OCR a vo vývojovej časti má 9,8 % príspevkov text *iba* v obrázku. V testovacej časti takéto príspevky nie sú, preto vplyv OCR na vývojovej množine môže byť väčší ako na testovacej.

- **Medzijazyková testovacia množina je nevyvážená**: podľa detegovaného jazyka tvoria hindské príspevky 40,9 % a páry hindčina→angličtina 43,5 % všetkých správnych párov; 73,9 % správnych fact-checkov je v angličtine. Vo vývojovej časti je podiel hindčiny len

Tabuľka 1: Štatistiky monolingválnej úlohy: počty príspevkov, veľkosť kolekcie kandidátov (podľa `tasks.json`), počet správnych párov a podiel príspevkov s viac ako jedným správnym fact-checkom.

	Trénovacia a vývojová časť					Testovacia časť			
Jazyk	train	dev	kolekcia	páry	>1 (%)	test	kolekcia	páry	>1 (%)
ara	676	78	14 201	78	0,0	500	21 153	514	2,8
deu	667	83	4 996	101	21,7	500	7 485	574	10,4
eng	4 351	478	85 734	627	21,1	500	145 287	740	26,4
fra	1 596	188	4 355	200	4,8	500	6 316	549	8,4
msa	1 062	105	8 424	116	9,5	93	686	96	3,2
pol	–	–	–	–	–	500	8 796	564	9,4
por	2 571	302	21 569	403	28,1	500	32 598	613	18,8
spa	5 628	615	14 082	692	11,4	500	25 440	576	12,8
tha	465	42	382	42	0,0	183	583	183	0,0
tur	–	–	–	–	–	500	12 536	550	9,0
spolu	17 016	1 891	153 743	2 259	15,5	4 276	260 880	4 959	11,5
Medzijazyková úloha									
všetky	4 972	552	153 743	651	14,3	4 000	272 447	5 322	20,5

14,3 %, takže výsledky na vývojovej a testovacej množine nemusia byť priamo porovnateľné (tab. 2). Zaujímavé je, že značná časť párov v medzijazykovej úlohe má podľa detektora *rovnaký* jazyk príspevku aj fact-checku (napr. eng→eng 20 % na teste); medzijazyková úloha sa teda od monolingválnej líši najmä neobmedzenou kolekciou kandidátov.

- **Fact-checky sú krátke** (medián 26 slov), príspevky dlhšie a variabilnejšie (90. percentil približne 190 slov), čo pri modeloch s limitom 512 tokenov vedie k orezaniu časti príspevkov.

4 Metodika

Metriky. Hlavnou metrikou úlohy je *Success@10* (S@10): podiel príspevkov, pre ktoré je medzi prvými desiatimi vrátenými fact-checkmi aspoň jeden správny. Metrika zodpovedá praktickému použitiu, keď overovateľ prezrie krátky zoznam kandidátov. Doplnkovo uvádzame *Mean Reciprocal Rank* orezaný na 10 (MRR@10), ktorý zohľadňuje aj pozíciu prvého správneho výsledku. V monolingválnej úlohe sa S@10 počíta pre každý jazyk zvlášť a výsledok je ich priemerom (každý jazyk má rovnakú váhu bez ohľadu na počet príspevkov); v medzijazykovej úlohe sa počíta cez všetky príspevky naraz. Takto počítajú výsledky aj oficiálne hodnotiace skripty.

Protokol hodnotenia.

- Všetky návrhové rozhodnutia (variant textu, nastavenia analyzátora) robíme **iba na vývojovej množine**. Na testovacej množine spúšťame každú vybranú konfiguráciu práve raz a výsledky slúžia len na finálne porovnanie.
- Kolekciu kandidátov pre každý príspevok berieme presne podľa `tasks.json`: v monolingválnej úlohe fact-checky jazyka príspevku, v medzijazykovej všetkých 153 743 (vývoj) resp. 272 447 (test) fact-checkov.

Tabuľka 2: Medzijazyková úloha: najčastejšie kombinácie jazyka príspevku a jazyka správneho fact-checku (podiel zo všetkých správnych párov). Jazyk je detegovaný (Google Translate), nie anotovaný.

Vývojová časť (651 párov)		Testovacia časť (5 322 párov)	
príspevok → fact-check	%	príspevok → fact-check	%
hin → eng	15,2	hin → eng	43,5
spa → spa	14,0	eng → eng	20,2
eng → eng	13,4	ara → ara	4,4
por → por	8,9	spa → spa	4,2
zho → eng	7,4	eng → hin	3,2
sin → eng	6,9	ben → eng	2,7
urd → eng	5,5	tur → tur	2,7
tgl → eng	5,1	urd → eng	2,6
fact-checky v angličtine	60,7	fact-checky v angličtine	73,9

Tabuľka 3: Zloženie a dĺžka textov (vývojová a testovacia časť, hodnotené príspevky oboch podúloh). Dĺžka je počet slov oddelených medzerami v anglickom preklade (medián / 90. percentil).

	Vývojová časť	Testovacia časť
Hodnotených príspevkov	2 443	8 276
Iba text používateľa (%)	45,6	53,3
Iba text z obrázka – OCR (%)	9,8	0,0
Text aj OCR (%)	44,6	46,7
Dĺžka príspevku, monolingválna	45 / 198	45 / 187
Dĺžka príspevku, medzijazyková	42 / 198	39 / 141
Dĺžka fact-checku (tvrdenie + názov)	26 / 41	27 / 46

- Naša implementácia metrík je overená proti oficiálnym hodnotiacim skriptom: na štyroch oficiálnych baseline predikciách organizátorov dáva presne rovnaké hodnoty ako uvádza článok organizátorov. Každý súbor s predikciami vyhodnocujeme oboma implementáciami.
- Všetky experimenty sú riadené konfiguračnými súbormi, majú fixované náhodné semienka a ukladajú metriky aj použitú konfiguráciu.

Reprezentácia textu. Text príspevku tvorí používateľský text spojený so všetkými OCR textami; text fact-checku tvorí tvrdenie spojené s názvom. Porovnávame tri varianty: originálny text (*orig*), anglický preklad (*eng*) a ich spojenie (*both*).

5 Baseline riešenia

BM25. Implementovali sme BM25 (Okapi, $k_1 = 1{,}5$, $b = 0{,}75$) pomocou riedkych matíc, aby bolo vyhľadávanie v kolekcii s 270 tis. dokumentmi rýchle (5–25 s na celý beh). Výsledky sú overené testom zhody s knižnicou `rank_bm25`. Základná verzia používa tokenizáciu na slová (`\w+`) bez ďalšieho spracovania. Upravená verzia pridáva jazykovo špecifické stemovanie (Snowball), odstraňovanie stop slov a segmentáciu thajčiny pomocou knižnice PyThaiNLP [13]. Thajčina nepoužíva medzery medzi slovami a samohláskové a tónové znamienka nepatria do triedy `\w`, takže základná tokenizácia rozbije thajský text na nezmyselné fragmenty.

Tabuľka 4: Hlavné výsledky na testovacej množine. Monolingválna S@10 a MRR@10 sú priemerom cez 10 jazykov, medzijazykové sú počítané cez všetky príspevky. Hodnoty organizátorov sme prepočítali z ich zverejnených predikcií (S@10 sa zhoduje s publikovanými hodnotami na 10^{-4}). Najlepší výsledok v stĺpci je zvýraznený.

	Monolingválna		Medzijazyková	
Systém	S@10	MRR@10	S@10	MRR@10
Baseline organizátorov				
BM25	0,812	0,653	0,603	0,382
paraphrase-multilingual-mpnet-v2	0,568	0,395	0,411	0,253
GTR-T5-large	0,730	0,503	**0,705**	**0,442**
multilingual-E5-large	0,859	0,688	0,637	0,395
Naše baseline				
BM25, základná tokenizácia (eng)	0,771	0,622	0,537	0,339
BM25 + stem. + stop slová + thajčina[a]	0,868	0,713	0,623	0,382
multilingual-E5-large[b]	**0,886**	**0,725**	0,681	0,417

[a] Monolingválna: variant *both*; medzijazyková: *eng* so stemovaním a stop slovami. [b] Monolingválna: *both*; medzijazyková: *eng*. Varianty boli vybrané na vývojovej množine.

Husté vyhľadávanie (multilingual-E5-large). Používame model `intfloat/multilingual-e5-large` [24] bez dotrénovania, s predponami `query:` a `passage:` podľa odporúčania autorov a maximálnou dĺžkou vstupu 512 tokenov. Reprezentácie všetkých fact-checkov vypočítame raz (fp16, GPU RTX 5070 s 8 GB) a uložíme na disk; výpočet pre 270 tis. fact-checkov trvá približne 5–7 minút. Vyhľadávanie je skalárny súčin normalizovaných vektorov (menej ako 1 s na celú množinu).

6 Výsledky

Interpretácia.

- **Husté vyhľadávanie je lepšie ako lexikálne**, najmä v medzijazykovej úlohe (0,681 oproti 0,623 na teste), kde majú príspevok a fact-check často málo spoločných slov.
- **Spracovanie textu je pre BM25 zásadné.** Odstránenie stop slov bolo najväčším jednotlivým zlepšením (napr. nemčina na vývojovej množine z 0,578 na 0,747) a segmentácia thajčiny zlepšila thajčinu z 0,738 na 0,857 pri originálnom texte. Upravené BM25 (0,868) prekonáva oficiálne BM25 organizátorov (0,812) aj ich E5 baseline (0,859).
- **Variant textu závisí od podúlohy.** V monolingválnej úlohe pomáha spojenie originálu s prekladom (E5: 0,862 oproti 0,827 len s angličtinou na vývojovej množine), zatiaľ čo v medzijazykovej úlohe škodí (0,533 oproti 0,591). Rovnaký smer rozdielov uvádza tím QUST_NLP vo svojich abláciách modelov E5 [8]. Pravdepodobné vysvetlenie (zatiaľ neoverené): v monolingválnej úlohe originál zachytí presné formulácie a preklad pridá robustnosť; v medzijazykovej úlohe sú fact-checky prevažne v inom jazyku ako príspevok, preto originálny text do reprezentácie pridáva skôr šum.
- **Výsledky po jazykoch.** Najnižšie S@10 nášho E5 má portugalčina (0,802), nasledovaná angličtinou (0,814; tabuľka 6). Vplyv veľkosti kolekcie overíme samostatne.

Tabuľka 5: Ablácie na vývojovej množine (S@10). Na základe týchto výsledkov sme vybrali konfigurácie pre testovaciu množinu (zvýraznené). Varianty textu: *orig* = originál, *eng* = anglický preklad, *both* = spojenie.

		Monolingválna									Medzijaz.
Model	Konfigurácia	ara	deu	eng	fra	msa	por	spa	tha	priem.	S@10
BM25	eng	0,705	0,518	0,546	0,750	0,619	0,735	0,724	0,881	0,685	0,413
BM25	orig	0,731	0,530	0,540	0,761	0,752	0,785	0,766	0,738	0,700	–
BM25	eng + stem	0,731	0,578	0,569	0,771	0,724	0,752	0,753	0,905	0,723	–
BM25	eng + stem + stop	0,782	0,747	0,630	0,793	0,733	0,811	0,807	0,881	0,773	**0,520**
BM25	orig + thai	0,731	0,530	0,540	0,761	0,752	0,785	0,766	0,857	0,715	–
BM25	orig + stem + stop + thai	0,782	0,723	0,626	0,824	0,733	0,775	0,846	0,905	0,777	–
BM25	both + stem + stop + thai	0,795	0,759	0,626	0,819	0,790	0,808	0,842	0,905	**0,793**	0,489
mE5	eng	0,808	0,759	0,797	0,862	0,790	0,772	0,854	0,976	0,827	**0,591**
mE5	orig	0,808	0,783	0,780	0,846	0,790	0,798	0,807	0,952	0,821	0,534
mE5	both	0,859	0,819	0,795	0,867	0,895	0,838	0,868	0,952	**0,862**	0,533
# príspevkov (dev)		78	83	478	188	105	302	615	42	1 891	552

Tabuľka 6: S@10 po jazykoch na testovacej množine (monolingválna úloha). Poľština (pol) a turečtina (tur) sa v trénovacích dátach nenachádzajú.

Systém	ara	deu	eng	fra	msa	pol	por	spa	tha	tur	priemer
BM25 (org.)	0,846	0,812	0,750	0,822	0,914	0,732	0,754	0,796	0,907	0,790	0,812
mE5 (org.)	0,916	**0,872**	**0,818**	0,854	0,860	0,798	0,808	0,856	0,929	0,878	0,859
BM25 upravené (naše)	0,930	0,860	0,760	**0,898**	0,957	0,814	**0,816**	**0,862**	0,945	0,840	0,868
mE5 (naše)	**0,942**	**0,872**	0,814	**0,898**	**0,978**	**0,830**	0,802	**0,862**	**0,984**	**0,880**	**0,886**
# príspevkov	500	500	500	500	93	500	500	500	183	500	4 276
veľkosť kolekcie	21 153	7 485	145 287	6 316	686	8 796	32 598	25 440	583	12 536	

- **Naše E5 prekonáva E5 organizátorov** (0,886 oproti 0,859). Najväčšie rozdiely voči E5 organizátorov sú v malajčine (+0,118), thajčine (+0,055) a francúzštine (+0,044). V nemčine je skóre rovnaké (0,872); v angličtine kleslo z 0,818 na 0,814 a v portugalčine z 0,808 na 0,802.
- **Obmedzenie:** pri variante *both* sa 11 % príspevkov nezmestí do 512 tokenov a ich koniec sa oreže.

7 Plán 2. etapy

1. **Fúzia** BM25 a hustého vyhľadávania pomocou RRF [3]: lexikálne a husté vyhľadávanie robia odlišné chyby.
2. **Dotrénovanie bi-enkodéra** (mE5) kontrastívnou stratou na trénovacích pároch (približne 20 tis. monolingválnych a 6 tis. medzijazykových) so ťažkými negatívnymi príkladmi získanými z našich baseline výsledkov; podľa literatúry ide o najväčší zdroj zlepšenia [4, 5]. Trénovanie prebehne na GPU T4 (Google Colab).
3. **Preusporiadanie** 50 najlepších kandidátov cross-enkodérom (napr. `bge-reranker-v2-m3`).
4. **Vlastný príspevok:** riešenie orezávania dlhých príspevkov a využitie metadát, najmä časovej blízkosti príspevku a fact-checku, ako ďalšieho signálu pri usporiadaní.

5. **Analýza chýb** s vopred definovanou taxonómiou, nezávislou anotáciou dvoma členmi tímu a overením navrhnutej úpravy na oddelených dátach.

6. **Demo** pre externých používateľov, ktoré zobrazuje skóre a odkaz na verejný fact-check (nie texty z dátovej množiny).

Každý krok vyhodnotíme na vývojovej množine ako ablačný experiment voči predchádzajúcemu najlepšiemu systému.

8 Reprodukovateľnosť

Kód je v repozitári `https://github.com/Mekr0t/FCCR`. Súbor `README.md` popisuje inštaláciu, umiestnenie dát a spúšťanie experimentov. Každý experiment je definovaný konfiguračným súborom v `configs/` a výsledky sú v `results/`. Testovacia sada (pytest) overuje načítanie dát, metriky, zhodu BM25 s referenčnou knižnicou a správanie analyzátora. Dátová množina nie je súčasťou repozitára kvôli licencii a treba si ju vyžiadať od organizátorov.

Literatúra

[1] Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar, editors, *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.findings-acl.137. URL `https://aclanthology.org/2024.findings-acl.137/`.

[2] Radu-Gabriel Chivereanu and Dan Tufis. RACAI at SemEval-2025 task 7: Efficient adaptation of large language models for multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 551–557, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL `https://aclanthology.org/2025.semeval-1.77/`.

[3] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759. ACM, 2009. doi: 10.1145/1571941.1572114.

[4] Prasanna Devadiga, Arya Suneesh, Pawan Rajpoot, Bharatdeep Hazarika, and Aditya Baliga. TIFIN India at SemEval-2025: Harnessing translation to overcome multilingual IR challenges in fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2297–2304, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL `https://aclanthology.org/2025.semeval-1.299/`.

[5] Alexandru Enache. UniBuc-AE at SemEval-2025 task 7: Training text embedding models for multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 634–639, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL `https://aclanthology.org/2025.semeval-1.89/`.

[6] Ashkan Kazemi, Kiran Garimella, Devin Gaffney, and Scott A. Hale. Claim matching beyond English to scale global fact-checking. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 4504–4517, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.347. URL https://aclanthology.org/2021.acl-long.347/.

[7] Ladislav Lenc, Daniel Cífka, Jiri Martinek, Jakub Šmíd, and Pavel Kral. UWBa at SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 209–215, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.31/.

[8] Youzheng Liu, Jiyan Liu, Xiaoman Xu, Taihang Wang, Yimin Wang, and Ye Jiang. QUST_NLP at SemEval-2025 task 7: A three-stage retrieval framework for monolingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 834–840, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.114/.

[9] Jianmo Ni, Chen Qu, Jing Lu, Zhuyun Dai, Gustavo Hernandez Abrego, Ji Ma, Vincent Zhao, Yi Luan, Keith Hall, Ming-Wei Chang, and Yinfei Yang. Large dual encoders are generalizable retrievers. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 9844–9855, Abu Dhabi, United Arab Emirates, December 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.669. URL https://aclanthology.org/2022.emnlp-main.669/.

[10] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019.

[11] Qiwei Peng, Robert Moro, Michal Gregor, Ivan Srba, Simon Ostermann, Marian Simko, Juraj Podrouzek, Matúš Mesarčík, Jaroslav Kopčan, and Anders Søgaard. SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2498–2511, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.323/.

[12] Qiwei Peng, Robert Moro, Michal Gregor, Ivan Srba, Simon Ostermann, Marian Simko, Juraj Podroužek, Matúš Mesarčík, Jaroslav Kopčan, and Anders Søgaard. SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval (dataset). Zenodo, https://doi.org/10.5281/zenodo.14989176, 2025.

[13] Wannaphong Phatthiyaphaibun, Korakot Chaovavanich, Charin Polpanumas, Arthit Suriyawongkul, Lalita Lowphansirikul, Pattarawat Chormai, Peerat Limkonchotiwat, Thanathip Suntorntip, and Can Udomcharoenchaikit. PyThaiNLP: Thai natural language processing in python. In Liling Tan, Dmitrijs Milajevs, Geeticka Chauhan, Jeremy Gwinnup, and Elijah Rippeth, editors, *Proceedings of the 3rd Workshop for Natural Language Processing Open Source Software (NLP-OSS 2023)*, pages 25–36, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.nlposs-1.4. URL https://aclanthology.org/2023.nlposs-1.4/.

[14] Matúš Pikuliak, Ivan Srba, Robert Moro, Timo Hromadka, Timotej Smoleň, Martin Melišek, Ivan Vykopal, Jakub Simko, Juraj Podroužek, and Maria Bielikova. Multilingual previously fact-checked claim retrieval. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 16477–16500, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.1027. URL https://aclanthology.org/2023.emnlp-main.1027/.

[15] Pranshu Rastogi. fact check AI at SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2352–2357, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.306/.

[16] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL https://aclanthology.org/D19-1410/.

[17] Nils Reimers and Iryna Gurevych. Making monolingual sentence embeddings multilingual using knowledge distillation. In Bonnie Webber, Trevor Cohn, Yulan He, and Yang Liu, editors, *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4512–4525, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.365. URL https://aclanthology.org/2020.emnlp-main.365/.

[18] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/1500000019.

[19] Shaden Shaar, Nikolay Babulkov, Giovanni Da San Martino, and Preslav Nakov. That is a known lie: Detecting previously fact-checked claims. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 3607–3618, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.332. URL https://aclanthology.org/2020.acl-main.332/.

[20] Shaden Shaar, Firoj Alam, Giovanni Da San Martino, and Preslav Nakov. The role of context in detecting previously fact-checked claims. In Marine Carpuat, Marie-Catherine de Marneffe, and Ivan Vladimir Meza Ruiz, editors, *Findings of the Association for Computational Linguistics: NAACL 2022*, pages 1619–1631, Seattle, United States, July 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-naacl.122. URL https://aclanthology.org/2022.findings-naacl.122/.

[21] Shujauddin Syed and Ted Pedersen. Duluth at SemEval-2025 task 7: TF-IDF with optimized vector dimensions for multilingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 712–717, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.98/.

[22] Nguyen Vo and Kyumin Lee. Where are the facts? searching for fact-checked information to alleviate the spread of fake news. In *Proceedings of the 2020 Conference on Empirical*

Methods in Natural Language Processing (EMNLP), pages 7717–7731, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.621. URL `https://aclanthology.org/2020.emnlp-main.621/`.

[23] Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*, 2022.

[24] Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*, 2024.

A Použitie LLM a AI agentov

[TODO: Preložiť a vložiť obsah súboru `docs/llm_usage.md` (nástroj, model, účel, prompty, výstupy).]