Viacjazyčné a medzijazykové vyhľadávanie overených tvrdení

SemEval-2025 Task 7 – 1. etapa: návrh projektu a baseline riešenie

Viktor Hančovský, Benjamín Konkoľ, Jakub Spišák, Roman Šafranko

25. októbra 2026

Abstrakt

Zaoberáme sa úlohou SemEval-2025 Task 7: pre príspevok zo sociálnej siete treba v kolekcii stoviek tisíc už overených tvrdení (fact-checkov) nájsť tie, ktoré sa ho týkajú, a to aj vtedy, keď sú príspevok a fact-check v rôznych jazykoch. V prvej etape sme implementovali reprodukovateľný experimentálny rámec s oficiálnym protokolom hodnotenia a dve baseline riešenia: lexikálne BM25 a husté vyhľadávanie pomocou modelu multilingual-E5-large bez dotrénovania. Na testovacej množine dosahuje náš E5 baseline S@10 0,886 (monolingválna úloha) a 0,681 (medzijazyková úloha). Naše E5 prekonáva E5 baseline organizátorov v oboch podúlohách (0,859 a 0,637); v medzijazykovej úlohe však zaostáva za ich GTR-T5-Large baseline (0,705). Upravené BM25 so stemovaním, odstraňovaním stop slov a segmentáciou thajčiny dosahuje 0,868 a 0,623.

1 Úvod

Problém. Manuálne overovanie tvrdení je časovo náročné a vyžaduje prácu profesionálnych overovateľov faktov (fact-checkerov) [19]. Veľká časť nepravdivých tvrdení sa však opakuje: to isté tvrdenie sa objavuje v nových príspevkoch, v iných formuláciách, na iných platformách a často aj v iných jazykoch. Ak by overovateľ vedel pre nový príspevok rýchlo nájsť už existujúci fact-check, nemusí tvrdenie overovať znova. Takáto úloha sa nazýva *vyhľadávanie už overených tvrdení* (previously fact-checked claim retrieval) [19].

Formulácia úlohy. Pre príspevok p zo sociálnej siete (text, prípadne text extrahovaný z priložených obrázkov pomocou optického rozpoznávania znakov, OCR) a kolekciu fact-checkov $\mathcal{F}$ má systém vrátiť usporiadaný zoznam fact-checkov tak, aby sa relevantné fact-checky nachádzali čo najvyššie. Ide o úlohu *vyhľadávania a usporiadania* (ranking), nie o klasifikáciu pravdivosti. Úloha SemEval-2025 Task 7 [11] má dve podúlohy:

- **monolingválnu** — príspevok aj fact-check sú v rovnakom jazyku a kolekcia kandidátov je obmedzená na fact-checky v jazyku príspevku,
- **medzijazykovú** (crosslingual) — príspevok a fact-check môžu byť v rôznych jazykoch a kolekcia kandidátov nie je obmedzená.

Motivácia. Fact-checky existujú prevažne vo veľkých jazykoch (najmä v angličtine), zatiaľ čo dezinformácie sa šíria vo všetkých jazykoch. Medzijazykové vyhľadávanie umožňuje znovu využiť existujúcu prácu overovateľov aj v jazykoch, kde je ich málo [11, 14].

Ciele projektu.

1. Vytvoriť reprodukovateľný experimentálny rámec s oficiálnym protokolom hodnotenia (1. etapa).

2. Implementovať a vyhodnotiť lexikálne a husté baseline riešenie (1. etapa).

3. Navrhnúť vlastné riešenie, ktoré baseline podstatne zlepší: fúziu výsledkov, dotrénovanie modelu na trénovacích pároch s ťažkými negatívnymi príkladmi a preusporiadanie kandidátov (2. etapa).

4. Systematicky analyzovať chyby a výsledky interpretovať po jazykoch (2. etapa).

Projekt sa zameriava primárne na monolingválnu podúlohu; medzijazykovú podúlohu vyhodnocujeme paralelne, keďže zdieľa celý systém aj predvypočítané reprezentácie.

2 Prehľad existujúcich prístupov

Vyhľadávanie už overených tvrdení. Shaar et al. [19] úlohu formulovali a použili dvojfázový prístup: kandidátov získali pomocou BM25 a preusporiadali ich pomocou rankSVM so znakmi odvodenými z BM25 a Sentence-BERT (učenie sa usporiadania, learning to rank). Vo and Lee [22] vyhľadávali fact-checkové články k tweetom s využitím textu aj obrázkov, čo je relevantné aj pre nás, keďže časť príspevkov obsahuje text iba v obrázku. Shaar et al. [20] ukázali, že kontext na strane vstupného tvrdenia v politickej debate môže zlepšiť vyhľadávanie o viac ako 10 bodov MAP; nejde o priamy experiment s OCR príspevkov zo sociálnych sietí. Kazemi et al. [6] rozšírili párovanie tvrdení na jazyky mimo angličtiny (hindčina, bengálčina, malajálamčina, tamilčina) pomocou destilovaného viacjazyčného modelu viet. Pikuliak et al. [14] vytvorili dátovú množinu MultiClaim (približne 28 tis. príspevkov v 27 jazykoch a 206 tis. fact-checkov v 39 jazykoch), z ktorej vychádza aj táto úloha. Pri vyhľadávaní nad anglickým prekladom patril medzi najlepšie modely bez dotrénovania GTR-T5-Large [9]; pre originálne texty autori vybrali MPNet-Base-Multilingual (tabuľka 2 ich článku).

Reprezentácie textu pre vyhľadávanie. Klasickým lexikálnym modelom je BM25 [18]. Husté vyhľadávanie používa bi-enkodéry, ktoré zakódujú dotaz a dokument nezávisle do vektora a podobnosť počítajú ako kosínusovú podobnosť [16]. Viacjazyčné bi-enkodéry vznikajú destiláciou z jednojazyčných modelov [17] alebo kontrastívnym predtrénovaním na veľkých viacjazyčných korpusoch, napríklad modely E5 [23, 24] a BGE-M3 [1]. Presnejšie, ale pomalšie sú cross-enkodéry, ktoré spracujú dotaz aj dokument naraz a používajú sa na preusporiadanie malého počtu kandidátov [10]. Výsledky viacerých vyhľadávačov sa dajú kombinovať pomocou reciprocal rank fusion [3].

Riešenia v SemEval-2025 Task 7. Súťaže sa zúčastnilo 179 registrovaných účastníkov s 52 testovacími odovzdaniami [11]. Poradia a nasledujúce monolingválne skóre preberáme z oficiálneho prehľadu (tabuľka 8); články tímov môžu uvádzať iné zaokrúhlenie. Najlepší výsledok bol S@10 0,9601, desiate miesto 0,9232. Zdokumentované systémy často kombinujú husté vyhľadávanie s preusporiadaním alebo fúziou modelov, existujú však aj silné systémy bez týchto krokov.

- **TIFIN India** [4] (3. miesto, 0,9383): preklad príspevkov do angličtiny modelom Aya-expanse-8B, dotrénovanie Stella-400M s ťažkými negatívnymi príkladmi, preusporiadanie 50 kandidátov modelom Qwen2.5-72B a RRF. Samotný dotrénovaný vyhľadávač s prekladmi dosiahol 0,9217 (tabuľka 5 článku).

- **RACAI** [2] (4. miesto, 0,9377): BGE-Multilingual-Gemma2-9B na originálnych textoch, kontrastívne dotrénovaný pomocou LoRA, bez preusporiadania. Prompt tuning, QLoRA a Matryoshka reprezentácie skúmali samostatne; nemožno ich všetky pripísať finálnej konfigurácii.

- **QUST_NLP** [8] (5. miesto, 0,9365): výber vyhľadávačov podľa jazyka, preusporiadanie a vážené hlasovanie. V abláciách modelov E5 spojenie originálu s prekladom zlepšilo monolingválny priemer, zatiaľ čo v medzijazykovej úlohe bol lepší samotný preklad (§4.1, tabuľky 1–2 článku); nejde o pravidlo pre každý model a jazyk.
- **UniBuc-AE** [5] (6. miesto, 0,9336): anglický e5-large-v2 a viacjazyčný multilingual-e5-large-instruct, kontrastívne učenie a následné dotrénovanie s ťažkými negatívnymi príkladmi. Štyri konfigurácie kombinujú váženými skóre podobnosti, s váhami vybranými na validačných dátach.
- **UWBa** [7] (7. miesto, 0,9270): bez dotrénovania, nad anglickými prekladmi. Finálny monolingválny systém podľa jazyka vyberá NV-Embed-v2 samostatne alebo v dvojici s GPT či Mistral; medzijazykový systém používa iba NV-Embed. Päť modelov skúmali pri predbežnom výbere, nie vo finálnej spoločnej kombinácii.
- **fact check AI** [15] (10. miesto, 0,9232): dotrénované bi-enkodéry a kombinovanie modelov trénovaných v piatich foldoch. Monolingválne spracovanie využíva originály aj preklady, medzijazykové anglické preklady.
- **Duluth** [21]: finálny lexikálny systém TF-IDF so slovnou tokenizáciou a 15 000 príznakmi dosiahol 0,6883 (tabuľka 3 článku; zaokrúhlene 0,69).

Tieto výsledky motivujú samostatne overiť prínos dotrénovania, preusporiadania a fúzie na našej vývojovej množine; nezaručujú zlepšenie pre každú konfiguráciu. Výpočtové nároky publikovaných veľkých modelov nemožno preniesť na našu 8 GB GPU bez samostatného overenia; v 2. etape preto plánujeme menšie modely a dotrénovanie na vzdialenej GPU.

3 Dáta

Používame oficiálnu dátovú množinu úlohy [12], ktorá je dostupná na výskumné účely na základe žiadosti. Trénovacia a vývojová časť vychádza z MultiClaim [14]; testovacia časť obsahuje nové dáta zozbierané rovnakou metodikou.

Štruktúra. Každý *príspevok* obsahuje text napísaný používateľom a texty extrahované z priložených obrázkov (OCR, Google Vision API). Každý *fact-check* obsahuje overované tvrdenie (claim) a názov článku (title). Všetky texty sú dostupné v origináli aj v anglickom preklade (Google Translate) spolu s detegovaným jazykom. Rozdelenie na podúlohy, trénovacie, vývojové a testovacie príspevky aj kolekciu kandidátov pre každú podúlohu definuje súbor `tasks.json`. Monolingválna úloha má v trénovacej a vývojovej časti 8 jazykov (ara, deu, eng, fra, msa, por, spa, tha); testovacia časť pridáva poľštinu a turečtinu, ktoré neboli vopred ohlásené.

Základné štatistiky oboch podúloh uvádzame v tabuľke 1; zloženie a dĺžku textov sumarizuje tabuľka 3.

Pozorovania.

- **Veľkosti kolekcií sa líšia o tri rády**: od 382 (thajčina) po 145 287 (angličtina, test). Rozdielna veľkosť kolekcie môže ovplyvniť náročnosť vyhľadávania; priemerovanie cez jazyky dáva malým jazykom rovnakú váhu ako angličtine. Niektoré vývojové množiny sú veľmi malé (thajčina 42, arabčina 78 príspevkov), takže rozdiely v jednotlivých jazykoch na vývojovej množine treba interpretovať opatrne.
- **Približne 11–21 % príspevkov má viac správnych fact-checkov v súhrne za podúlohu a split** (rovnaké tvrdenie overilo viacero organizácií). Pri hodnotení S@10 stačí nájsť ktorýkoľvek z nich.

Tabuľka 1: Základné štatistiky monolingválnej úlohy a v spodnej časti medzijazykovej úlohy: počty príspevkov, veľkosť kolekcie kandidátov (podľa `tasks.json`), počet správnych párov a podiel hodnotených príspevkov s viac ako jedným správnym fact-checkom.

	Trénovacia a vývojová časť					Testovacia časť			
Jazyk	train	dev	kolekcia	páry	>1 (%)	test	kolekcia	páry	>1 (%)
ara	676	78	14 201	78	0,0	500	21 153	514	2,8
deu	667	83	4 996	101	21,7	500	7 485	574	10,4
eng	4 351	478	85 734	627	21,1	500	145 287	740	26,4
fra	1 596	188	4 355	200	4,8	500	6 316	549	8,4
msa	1 062	105	8 424	116	9,5	93	686	96	3,2
pol	–	–	–	–	–	500	8 796	564	9,4
por	2 571	302	21 569	403	28,1	500	32 598	613	18,8
spa	5 628	615	14 082	692	11,4	500	25 440	576	12,8
tha	465	42	382	42	0,0	183	583	183	0,0
tur	–	–	–	–	–	500	12 536	550	9,0
spolu	17 016	1 891	153 743	2 259	15,5	4 276	260 880	4 959	11,5
Medzijazyková úloha									
všetky	4 972	552	153 743	651	14,3	4 000	272 447	5 322	20,5

- **Text v obrázkoch je dôležitý**: OCR obsahuje 54,4 % vývojových a 46,7 % testovacích príspevkov oboch podúloh; vo vývojovej časti má 9,8 % príspevkov text *iba* v obrázku. V testovacej časti takéto príspevky nie sú, preto vplyv OCR na vývojovej množine môže byť väčší ako na testovacej.
- **Medzijazyková testovacia množina je nevyvážená**: podľa detegovaného jazyka tvoria hindské príspevky 40,9 % a páry hindčina→angličtina 43,5 % všetkých správnych párov; 73,9 % správnych fact-checkov je v angličtine. Vo vývojovej časti je podiel hindčiny len 14,3 %, takže výsledky na vývojovej a testovacej množine nemusia byť priamo porovnateľné (tab. 2). Zaujímavé je, že značná časť párov v medzijazykovej úlohe má podľa detektora *rovnaký* jazyk príspevku aj fact-checku (napr. eng→eng 20 % na teste); medzijazyková úloha sa teda od monolingválnej líši najmä neobmedzenou kolekciou kandidátov.
- **Fact-checky sú krátke**: medián dĺžky anglického textu je 26 slov na vývojovej a 27 slov na testovacej množine. Monolingválne príspevky sú dlhšie a variabilnejšie (90. percentil 198, resp. 187 slov); pri modeli s limitom 512 tokenov sa časť príspevkov oreže.

4 Metodika

Metriky. Hlavnou metrikou úlohy je *Success@10* (S@10): podiel príspevkov, pre ktoré je medzi prvými desiatimi vrátenými fact-checkmi aspoň jeden správny. Metrika zodpovedá praktickému použitiu, keď overovateľ prezrie krátky zoznam kandidátov. Doplnkovo uvádzame *Mean Reciprocal Rank* orezaný na 10 (MRR@10), ktorý zohľadňuje aj pozíciu prvého správneho výsledku. V monolingválnej úlohe sa S@10 počíta pre každý jazyk zvlášť a výsledok je ich priemerom (každý jazyk má rovnakú váhu bez ohľadu na počet príspevkov); v medzijazykovej úlohe sa počíta cez všetky príspevky naraz. Takto počítajú výsledky aj oficiálne hodnotiace skripty.

Tabuľka 2: Medzijazyková úloha: najčastejšie kombinácie jazyka príspevku a jazyka správneho fact-checku (podiel zo všetkých správnych párov). Jazyk je detegovaný (Google Translate), nie anotovaný.

Vývojová časť (651 párov)		Testovacia časť (5 322 párov)	
príspevok → fact-check	%	príspevok → fact-check	%
hin → eng	15,2	hin → eng	43,5
spa → spa	14,0	eng → eng	20,2
eng → eng	13,4	ara → ara	4,4
por → por	8,9	spa → spa	4,2
zho → eng	7,4	eng → hin	3,2
sin → eng	6,9	ben → eng	2,7
urd → eng	5,5	tur → tur	2,7
tgl → eng	5,1	urd → eng	2,6
fact-checky v angličtine	60,7	fact-checky v angličtine	73,9

Tabuľka 3: Zloženie a dĺžka textov (vývojová a testovacia časť, hodnotené príspevky oboch podúloh). Dĺžka je počet slov oddelených medzerami v anglickom preklade (medián / 90. percentil).

	Vývojová časť	Testovacia časť
Hodnotených príspevkov	2 443	8 276
Iba text používateľa (%)	45,6	53,3
Iba text z obrázka – OCR (%)	9,8	0,0
Text aj OCR (%)	44,6	46,7
Dĺžka príspevku, monolingválna	45 / 198	45 / 187
Dĺžka príspevku, medzijazyková	42 / 198	39 / 141
Dĺžka fact-checku (tvrdenie + názov)	26 / 41	27 / 46

Protokol hodnotenia.

- Všetky návrhové rozhodnutia (variant textu, nastavenia analyzátora) robíme **iba na vývojovej množine**. Testovacie výsledky slúžia na finálne porovnanie vopred vybraných konfigurácií a kontrolu ich reprodukovateľnosti, nie na výber variantov.
- Kolekciu kandidátov pre každý príspevok berieme presne podľa `tasks.json`: v monolingválnej úlohe fact-checky jazyka príspevku, v medzijazykovej všetkých 153 743 (vývoj) resp. 272 447 (test) fact-checkov.
- Na oficiálnych baseline predikciách organizátorov sa naše S@10 zhoduje s publikovanými hodnotami s maximálnou odchýlkou menšou ako 10^{-4}. Na nezávislú kontrolu predikcií slúži skript `scripts/score_official.py`, ktorý porovnáva náš scorer s prevzatou oficiálnou hodnotiacou logikou.
- Všetky experimenty sú riadené konfiguračnými súbormi, majú fixované náhodné semienka a ukladajú metriky aj použitú konfiguráciu.

Reprezentácia textu. Text príspevku tvorí používateľský text spojený so všetkými OCR textami; text fact-checku tvorí tvrdenie spojené s názvom. Porovnávame tri varianty: originálny text (*orig*), anglický preklad (*eng*) a ich spojenie (*both*).

Tabuľka 4: Hlavné výsledky na testovacej množine. Monolingválna S@10 a MRR@10 sú priemerom cez 10 jazykov, medzijazykové sú počítané cez všetky príspevky. Hodnoty organizátorov sme prepočítali z ich zverejnených predikcií (S@10 sa zhoduje s publikovanými hodnotami na 10^{-4}). Najlepší výsledok v stĺpci je zvýraznený.

	Monolingválna		Medzijazyková	
Systém	S@10	MRR@10	S@10	MRR@10
Baseline organizátorov				
BM25	0,812	0,653	0,603	0,382
paraphrase-multilingual-mpnet-base-v2	0,568	0,395	0,411	0,253
GTR-T5-large	0,730	0,503	**0,705**	**0,442**
multilingual-E5-large	0,859	0,688	0,637	0,395
Naše baseline				
BM25, základná tokenizácia (eng)	0,771	0,622	0,537	0,339
BM25 + stem. + stop slová + thajčina[a]	0,868	0,713	0,623	0,382
multilingual-E5-large[b]	**0,886**	**0,725**	0,681	0,417

[a] Monolingválna: variant *both*; medzijazyková: *eng* so stemovaním a stop slovami. [b] Monolingválna: *both*; medzijazyková: *eng*. Varianty boli vybrané na vývojovej množine.

5 Baseline riešenia

BM25. Implementovali sme BM25 (Okapi, $k_1 = 1{,}5$, $b = 0{,}75$) pomocou riedkych matíc, aby bolo vyhľadávanie v kolekcii s 270 tis. dokumentmi rýchle. V pôvodných uložených behoch trvali finálne upravené testovacie konfigurácie približne 14–25 s; základná medzijazyková konfigurácia trvala približne 52 s. Časy závisia od hardvéru a dostupnosti cache spracovaných dát. Výsledky sú overené testom zhody s knižnicou `rank_bm25`. Základná verzia používa tokenizáciu na slová (`\w+`) bez ďalšieho spracovania. Upravená verzia pridáva jazykovo špecifické stemovanie (Snowball), odstraňovanie stop slov a segmentáciu thajčiny pomocou knižnice PyThaiNLP [13]. Thajčina nepoužíva medzery medzi slovami a niektoré samohláskové a tónové znamienka nepatria do triedy `\w`, takže základná tokenizácia rozdeľuje text aj vnútri slov.

Husté vyhľadávanie. Používame model `intfloat/multilingual-e5-large` [24] bez dotrénovania, s predponami `query:` a `passage:` podľa odporúčania autorov a maximálnou dĺžkou vstupu 512 tokenov. Reprezentácie fact-checkov vypočítame v fp16 a uložíme na disk. V pôvodnom prostredí projektu (podľa README GPU RTX 5070 s 8 GB) trvalo enkódovanie kolekcií s 261–272 tis. fact-checkmi približne 5–7 minút. Samotné vyhľadávanie je skalárny súčin normalizovaných vektorov; v pôvodných testovacích behoch trvalo menej ako 1 s na celú množinu.

6 Výsledky

Hlavné výsledky na testovacej množine uvádzame v tabuľke 4. Ablácie použité pri výbere konfigurácií sú v tabuľke 5; rozdelenie testovacích výsledkov po jazykoch je v tabuľke 6.

Interpretácia.

- **Naše husté vyhľadávanie dosiahlo vyššie skóre ako naše lexikálne riešenie**, najmä v medzijazykovej úlohe (0,681 oproti 0,623 na teste). Možným vysvetlením je nižší lexikálny prekryv medzi jazykmi; túto príčinu sme samostatne neoverovali.

Tabuľka 5: Ablácie na vývojovej množine (S@10). Na základe týchto výsledkov sme vybrali konfigurácie pre testovaciu množinu (zvýraznené). Varianty textu: *orig* = originál, *eng* = anglický preklad, *both* = spojenie.

		Monolingválna									Medzijaz.
Model	Konfigurácia	ara	deu	eng	fra	msa	por	spa	tha	priem.	S@10
BM25	eng	0,705	0,518	0,546	0,750	0,619	0,735	0,724	0,881	0,685	0,413
BM25	orig	0,731	0,530	0,540	0,761	0,752	0,785	0,766	0,738	0,700	–
BM25	eng + stem	0,731	0,578	0,569	0,771	0,724	0,752	0,753	0,905	0,723	–
BM25	eng + stem + stop	0,782	0,747	0,630	0,793	0,733	0,811	0,807	0,881	0,773	**0,520**
BM25	orig + thai	0,731	0,530	0,540	0,761	0,752	0,785	0,766	0,857	0,715	–
BM25	orig + stem + stop + thai	0,782	0,723	0,626	0,824	0,733	0,775	0,846	0,905	0,777	–
BM25	both + stem + stop + thai	0,795	0,759	0,626	0,819	0,790	0,808	0,842	0,905	**0,793**	0,489
mE5	eng	0,808	0,759	0,797	0,862	0,790	0,772	0,854	0,976	0,827	**0,591**
mE5	orig	0,808	0,783	0,780	0,846	0,790	0,798	0,807	0,952	0,821	0,534
mE5	both	0,859	0,819	0,795	0,867	0,895	0,838	0,868	0,952	**0,862**	0,533
# príspevkov (dev)		78	83	478	188	105	302	615	42	1 891	552

Tabuľka 6: S@10 po jazykoch na testovacej množine (monolingválna úloha). Poľština (pol) a turečtina (tur) sa medzi monolingválnymi trénovacími príspevkami nenachádzajú.

Systém	ara	deu	eng	fra	msa	pol	por	spa	tha	tur	priemer
BM25 (org.)	0,846	0,812	0,750	0,822	0,914	0,732	0,754	0,796	0,907	0,790	0,812
mE5 (org.)	0,916	**0,872**	**0,818**	0,854	0,860	0,798	0,808	0,856	0,929	0,878	0,859
BM25 upravené (naše)	0,930	0,860	0,760	**0,898**	0,957	0,814	**0,816**	**0,862**	0,945	0,840	0,868
mE5 (naše)	**0,942**	**0,872**	0,814	**0,898**	**0,978**	**0,830**	0,802	**0,862**	**0,984**	**0,880**	**0,886**
# príspevkov	500	500	500	500	93	500	500	500	183	500	4 276
veľkosť kolekcie	21 153	7 485	145 287	6 316	686	8 796	32 598	25 440	583	12 536	

- **Spracovanie textu je pre BM25 zásadné.** Odstránenie stop slov bolo najväčším jednotlivým zlepšením (napr. nemčina na vývojovej množine z 0,578 na 0,747) a segmentácia thajčiny zlepšila thajčinu z 0,738 na 0,857 pri originálnom texte. Upravené BM25 (0,868) prekonáva oficiálne BM25 organizátorov (0,812) aj ich E5 baseline (0,859).

- **Variant textu závisí od podúlohy.** V monolingválnej úlohe pomáha spojenie originálu s prekladom (E5: 0,862 oproti 0,827 len s angličtinou na vývojovej množine), zatiaľ čo v medzijazykovej úlohe škodí (0,533 oproti 0,591). Rovnaký smer rozdielov uvádza tím QUST_NLP vo svojich ablániách modelov E5 [8]. Pravdepodobné vysvetlenie (zatiaľ neoverené): v monolingválnej úlohe originál zachytí presné formulácie a preklad pridá robustnosť; v medzijazykovej úlohe sú fact-checky prevažne v inom jazyku ako príspevok, preto originálny text do reprezentácie pridáva skôr šum.

- **Výsledky po jazykoch.** Najnižšie S@10 nášho E5 má portugalčina (0,802), nasledovaná angličtinou (0,814; tabuľka 6). Vplyv veľkosti kolekcie overíme samostatne.

- **Naše E5 prekonáva E5 organizátorov** (0,886 oproti 0,859). Najväčšie rozdiely voči E5 organizátorov sú v malajčine (+0,118), thajčine (+0,055) a francúzštine (+0,044). V nemčine je skóre rovnaké (0,872); v angličtine kleslo z 0,818 na 0,814 a v portugalčine z 0,808 na 0,802.

- **Obmedzenie:** pri variante *both* sa do 512 tokenov nezmestí 478 zo 4 276 monolingválnych testovacích príspevkov (11,2 %) a ich koniec sa oreže. Na monolingválnej vývojovej množine ide o 219 z 1 891 príspevkov (11,6 %).

7 Plán 2. etapy

1. **Fúzia** BM25 a hustého vyhľadávania pomocou RRF [3]: overíme, či kombinácia ich poradí kandidátov zlepší výsledky.
2. **Dotrénovanie bi-enkodéra** (mE5) kontrastívnou stratou na trénovacích pároch s ťažkými negatívnymi príkladmi získanými iba pre trénovacie príspevky. Prínos tohto kroku podporujú ablácie TIFIN a UniBuc-AE [4, 5]; jeho veľkosť v našom systéme ešte len overíme. Trénovanie plánujeme na GPU T4 (Google Colab).
3. **Preusporiadanie kandidátov.** Cross-enkodér (napr. `bge-reranker-v2-m3`) preusporiada 50 najlepších kandidátov.
4. **Vlastný príspevok:** riešenie orezávania dlhých príspevkov a využitie metadát, najmä časovej blízkosti príspevku a fact-checku, ako ďalšieho signálu pri usporiadaní.
5. **Analýza chýb** s vopred definovanou taxonómiou, nezávislou anotáciou dvoma členmi tímu a overením navrhnutej úpravy na oddelených dátach.
6. **Demo** pre externých používateľov, ktoré zobrazuje skóre a odkaz na verejný fact-check (nie texty z dátovej množiny).

Každý krok vyhodnotíme na vývojovej množine ako ablačný experiment voči predchádzajúcemu najlepšiemu systému.

8 Reprodukovateľnosť

Kód je v repozitári `https://github.com/Mekr0t/FCCR`. Súbor `README.md` popisuje inštaláciu, umiestnenie dát a spúšťanie experimentov. Každý experiment je definovaný konfiguračným súborom v `configs/` a výsledky sú v `results/`. Testovacia sada (pytest) overuje načítanie dát, metriky, zhodu BM25 s referenčnou knižnicou a správanie analyzátora. Samostatná reprodukcia štyroch zmrazených konfigurácií na RTX 4060 Laptop (8 GB) je zdokumentovaná v `results/reproduction_20261022.md`: obe BM25 metriky sa zhodujú presne, dense metriky sú v absolútnej tolerancii ±0,005. Tabuľky v tejto správe uvádzajú pôvodné referenčné behy; reprodukčné merania ich neprepisujú. Dátová množina nie je súčasťou repozitára kvôli licencii a treba si ju vyžiadať od organizátorov.

Literatúra

[1] Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar, editors, *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.findings-acl.137. URL `https://aclanthology.org/2024.findings-acl.137/`.

[2] Radu-Gabriel Chivereanu and Dan Tufis. RACAI at SemEval-2025 task 7: Efficient adaptation of large language models for multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 551–557, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL `https://aclanthology.org/2025.semeval-1.77/`.

[3] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759. ACM, 2009. doi: 10.1145/1571941.1572114.

[4] Prasanna Devadiga, Arya Suneesh, Pawan Rajpoot, Bharatdeep Hazarika, and Aditya Baliga. TIFIN India at SemEval-2025: Harnessing translation to overcome multilingual IR challenges in fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2297–2304, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.299/.

[5] Alexandru Enache. UniBuc-AE at SemEval-2025 task 7: Training text embedding models for multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 634–639, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.89/.

[6] Ashkan Kazemi, Kiran Garimella, Devin Gaffney, and Scott A. Hale. Claim matching beyond English to scale global fact-checking. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 4504–4517, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.347. URL https://aclanthology.org/2021.acl-long.347/.

[7] Ladislav Lenc, Daniel Cífka, Jiri Martinek, Jakub Šmíd, and Pavel Kral. UWBa at SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 209–215, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.31/.

[8] Youzheng Liu, Jiyan Liu, Xiaoman Xu, Taihang Wang, Yimin Wang, and Ye Jiang. QUST_NLP at SemEval-2025 task 7: A three-stage retrieval framework for monolingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 834–840, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.114/.

[9] Jianmo Ni, Chen Qu, Jing Lu, Zhuyun Dai, Gustavo Hernandez Abrego, Ji Ma, Vincent Zhao, Yi Luan, Keith Hall, Ming-Wei Chang, and Yinfei Yang. Large dual encoders are generalizable retrievers. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 9844–9855, Abu Dhabi, United Arab Emirates, December 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.669. URL https://aclanthology.org/2022.emnlp-main.669/.

[10] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019.

[11] Qiwei Peng, Robert Moro, Michal Gregor, Ivan Srba, Simon Ostermann, Marian Simko, Juraj Podrouzek, Matúš Mesarčík, Jaroslav Kopčan, and Anders Søgaard. SemEval-2025

task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2498–2511, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.323/.

[12] Qiwei Peng, Robert Moro, Michal Gregor, Ivan Srba, Simon Ostermann, Marian Simko, Juraj Podroužek, Matúš Mesarčík, Jaroslav Kopčan, and Anders Søgaard. SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval (dataset). Zenodo, https://doi.org/10.5281/zenodo.14989176, 2025.

[13] Wannaphong Phatthiyaphaibun, Korakot Chaovavanich, Charin Polpanumas, Arthit Suriyawongkul, Lalita Lowphansirikul, Pattarawat Chormai, Peerat Limkonchotiwat, Thanathip Suntorntip, and Can Udomcharoenchaikit. PyThaiNLP: Thai natural language processing in python. In Liling Tan, Dmitrijs Milajevs, Geeticka Chauhan, Jeremy Gwinnup, and Elijah Rippeth, editors, *Proceedings of the 3rd Workshop for Natural Language Processing Open Source Software (NLP-OSS 2023)*, pages 25–36, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.nlposs-1.4. URL https://aclanthology.org/2023.nlposs-1.4/.

[14] Matúš Pikuliak, Ivan Srba, Robert Moro, Timo Hromadka, Timotej Smoleň, Martin Melišek, Ivan Vykopal, Jakub Simko, Juraj Podroužek, and Maria Bielikova. Multilingual previously fact-checked claim retrieval. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 16477–16500, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.1027. URL https://aclanthology.org/2023.emnlp-main.1027/.

[15] Pranshu Rastogi. fact check AI at SemEval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 2352–2357, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.306/.

[16] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL https://aclanthology.org/D19-1410/.

[17] Nils Reimers and Iryna Gurevych. Making monolingual sentence embeddings multilingual using knowledge distillation. In Bonnie Webber, Trevor Cohn, Yulan He, and Yang Liu, editors, *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4512–4525, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.365. URL https://aclanthology.org/2020.emnlp-main.365/.

[18] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/1500000019.

[19] Shaden Shaar, Nikolay Babulkov, Giovanni Da San Martino, and Preslav Nakov. That is a known lie: Detecting previously fact-checked claims. In *Proceedings of the 58th Annual*

Meeting of the Association for Computational Linguistics, pages 3607–3618, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.332. URL https://aclanthology.org/2020.acl-main.332/.

[20] Shaden Shaar, Firoj Alam, Giovanni Da San Martino, and Preslav Nakov. The role of context in detecting previously fact-checked claims. In Marine Carpuat, Marie-Catherine de Marneffe, and Ivan Vladimir Meza Ruiz, editors, *Findings of the Association for Computational Linguistics: NAACL 2022*, pages 1619–1631, Seattle, United States, July 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-naacl.122. URL https://aclanthology.org/2022.findings-naacl.122/.

[21] Shujauddin Syed and Ted Pedersen. Duluth at SemEval-2025 task 7: TF-IDF with optimized vector dimensions for multilingual fact-checked claim retrieval. In Sara Rosenthal, Aiala Rosá, Debanjan Ghosh, and Marcos Zampieri, editors, *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*, pages 712–717, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-273-2. URL https://aclanthology.org/2025.semeval-1.98/.

[22] Nguyen Vo and Kyumin Lee. Where are the facts? searching for fact-checked information to alleviate the spread of fake news. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7717–7731, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.621. URL https://aclanthology.org/2020.emnlp-main.621/.

[23] Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*, 2022.

[24] Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*, 2024.

A Použitie LLM a AI agentov

Rozsah a pôvod záznamov

Táto príloha obsahuje slovenský výklad všetkých 25 dostupných záznamov použitia AI v prvej etape. Zahŕňa aj skoršiu kontrolu reportu z 21. októbra, ktorej záznam 18 zostal v oddelenom lokálnom checkoute a bol doplnený bez zmien. Pôvodné záznamy v `docs/llm_usage.md` sa neprepisovali; preklad je zoradený podľa čísel záznamov.

Výklad, účel a výstupy sú po slovensky. Znenie zachovaných promptov uvádzame aj v pôvodnom jazyku, aby sa nestratil ich obsah. Ak samostatný prompt v pôvodnom zázname chýbal, uvádzame zachovaný opis zadania a túto medzeru výslovne pomenujeme.

Historické údaje o modeloch, výsledkoch a kontrolách preberáme zo zdrojového logu. Označenie *judge PASS 5/5* znamená deklarované overenie iným AI agentom; nepredstavuje ľudské potvrdenie. Historické počty testov sa líšia podľa konfigurácií, prítomných lokálnych predikcií a dostupného modelového prostredia. Nie sú výsledkami jedného spoločného nového behu.

Pôvodný log uvádza Claude Code, hlavný model Claude Opus 5.5 a worker/judge modely Claude Haiku/Sonnet. Tieto historické identifikátory neboli v tejto kontrole nezávisle overené. Neskoršie práce Jakuba prebiehali cez Codex desktop. Pri kontrole lokálneho prepisu 25. októbra bolo v metadátach zachovaných turnov nájdené označenie `gpt-6.1-sol`; skoršie menej presné označenie rodiny GPT-6 v záznamoch zostáva zachované.

Pokrytie častí projektu

Oblasť použitia AI	Záznamy
Načítanie dát, vyhľadávanie a analyzátor	1, 3, 7, 8, 16, 17
Metriky, štatistiky, tabuľky a reprodukcia	3, 7, 8, 11, 16, 17, 19, 25
Literárny prieskum a kontrola zdrojov	1, 10, 18, 21, 25
Návrh reportu a jeho opravy	12, 18, 21, 22, 25
README, pravidlá, git a CI	4–6, 9, 13–15, 20, 23
Evidencia AI a slovenská príloha	5, 18, 24, 25

Potvrdenia členov tímu

Preklad dostupného logu sám nepotvrdzuje úplnosť použitia AI za každého člena. Stav k príprave tejto verzie je uvedený nižšie. Nepotvrdené použitie neznamená, že daný člen AI nepoužil. Podrobný stav a spôsob doplnenia zachytáva `docs/ai_usage_confirmation.md`.

Člen	Výslovne priradené záznamy	Potvrdenie úplnosti
Viktor Hančovský	AI nepoužíval	oznámil Jakub Spišák
Benjamín Konkoľ	AI nepoužíval	oznámil Jakub Spišák
Jakub Spišák	18, 19, 21–25	zatiaľ nepotvrdené
Roman Šafranko	16, 20; ďalšie treba potvrdiť	zatiaľ nepotvrdené

Jakub Spišák 25. októbra 2026 oznámil, že zvyšní členovia tímu AI nepoužívali. Vzhľadom na už zdokumentované použitie Jakuba a Romana sa toto oznámenie vzťahuje na Viktora Hančovského a Benjamína Konkoľa; ide o sprostredkované oznámenie, nie o samostatné potvrdenia v tomto chate.

Iniciátor prvých dvoch relácií nebol v ich úvode výslovne pomenovaný. Priradenie týchto relácií konkrétnemu človeku nemožno doplniť iba odhadom.

Uloženie prepisov konverzácií

Pôvodný log deklaruje Claude Code JSONL prepisy u vlastníka pôvodnej relácie v nasledujúcom adresári:
`~/.claude/projects/D--skola-nlp-SemEval-2025/`
Dostupnosť a úplnosť tohto archívu na Romanovom počítači nebola v tejto relácii overená; daná cesta sa na použitom počítači nenašla.
Pre aktuálny Codex chat sa lokálne overila existencia JSONL súboru a zhoda ID relácie:
`~/.codex/sessions/2026/10/21/rollout-2026-10-21T17-22-03-01a15f0e-2007-7e92-9ff7-62745b0b0c13.jsonl`
Ide o priebežne zapisované lokálne úložisko aplikácie, nie o overený nemenný export pre odovzdanie. Pri kontrole sa čítali iba metadáta relácie a modelového označenia, nie obsah správ. Finálne umiestnenie spoločného súkromného archívu a jeho dostupnosť pre vyučujúceho ešte tím nepotvrdil. Prepisy sa do verejného repozitára nepridávajú.

Chronologické záznamy

Relácia 1: 12.–13. október 2026

Záznam 1 – Prieskum úlohy a vytvorenie projektu

Účel a zadanie. Pomôcť začať s replikáciou SemEval-2025 Task 7. Hlavným nástrojom bol podľa pôvodného logu Claude Code s modelom Claude Opus 5.5; worker používal Haiku. Iniciátor relácie 1 nebol v pôvodných záznamoch výslovne pomenovaný.

Činnosť a použité výstupy. Agent prešiel stránku úlohy, oficiálny repozitár `kinit-sk/semeval_2025`, prehľadový článok a Zenodo. Zhrnul obe podúlohy, metriku S@10, baseline systémy a spôsob žiadosti o dáta. Worker pripravil virtuálne prostredie a pripnuté závislosti, načítanie textov uložených ako reťazce reprezentujúce n-tice, metriky S@10 a MRR, jazykové/makro vyhodnotenie, BM25 skript a testy. Overenie prebehlo na verejnej vzorke.

Overenie a výsledok podľa logu. Judge agent uviedol PASS 5/5: testy prešli, metriky sa ručne prepočítali na skonštruovanom príklade a nenašiel únik gold anotácií. BM25 na vzorke dosiahlo S@10 0,957 pre anglický text a 0,702 pre originál. Kolekcia mala iba 50 fact-checkov, preto išlo o overenie spustenia, nie výsledok na oficiálnom teste.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”https://disai.eu/semeval-2025/ SemEval 2025 Shared Task 7: Multilingual and Crosslingual Fact-Checked Claim Retrieval - i need to replicate this, can you help me get started”

Záznam 2 – Problém s prístupom k dátam

Účel a zadanie. Používateľ nevedel vytvoriť účet potrebný na podanie žiadosti o dataset.

Nástroj a model. Claude Code; hlavný model podľa úvodu pôvodného logu Claude Opus 5.5.

Použitý výstup. Agent odporučil prihlásenie do Zenodo cez GitHub alebo ORCID, prípadne kontaktovanie organizátorov alebo vyučujúceho. Kód sa nemenil; záznam neuvádza experiment ani testovací výsledok.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”there may be a little problem, i cant create account to send request for dataset (error while creating account)”

Záznam 3 – Zapojenie oficiálneho datasetu

Účel a zadanie. Prispôsobiť pipeline oficiálnemu vydaniu, ktoré používateľ sprístupnil lokálne.

Nástroj a model. Claude Code, hlavný model podľa logu Opus 5.5; implementáciu vykonal worker Sonnet.

Činnosť a použité výstupy. Po prečítaní README dát a oficiálneho loadera/scorerov agent zistil štyri rozdiely: identifikátory fact-checkov musia byť celé čísla; treba aspoň desať predikcií pre každý príspevok; súbory párov nemajú stĺpec `pair_lang`; pôvodný `rank_bm25` je pri veľkých kolekciách príliš pomalý. Dáta presunul pod ignorované `data/raw/` a doplnil zistenia do `CLAUDE.md`. Worker pripravil načítanie splitov a kolekcií z `tasks.json`, riedkomaticové BM25, oficiálny formát predikcií, MRR@10 a skript porovnávajúci hodnotenie s nezávislou kópiou oficiálnej logiky.

Výsledky podľa logu. BM25 na dev pri anglickom texte dosiahlo S@10 mono 0,685 a cross 0,413; pri originálnom texte mono 0,700. Na teste malo mono 0,771 a cross 0,537. Vtedajší judge uviedol PASS 5/5, predikcie v správnych kolekciách a bez úniku anotácií. Za nižším skóre oproti organizátorom predpokladal tokenizáciu a zostavovanie textu; príčinu experimentálne nepotvrdil.

Historické obmedzenie. Log uvádzal presnú zhodu so všetkými štyrmi publikovanými baseline výsledkami. Neskoršie overenie v zázname 11 spresňuje maximálnu odchýlku na 0,00004. Pri diagnostike judge vykonal malé porovnanie textových variantov na troch testovacích jazykoch; podľa záznamu nebolo použité na návrhové rozhodnutie. Ladenie malo prebiehať na dev.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”got dataset its in root folder”

Záznam 4 – Príprava repozitára na GitHub

Účel a zadanie. Pripraviť repozitár na publikovanie pri zachovaní licenčných obmedzení dát.

Nástroj a model. Claude Code, hlavný model podľa pôvodného logu Opus 5.5.

Činnosť a výstup. Agent vytvoril `.gitignore` pre pôvodné dáta a odvodené súbory vrátane dodatočných ochranných vzorov, doplnil `.gitattributes` a README. Pri skúšobnej príprave súborov na commit skontroloval, že by sa nepridal dataset.

Overenie. V logu je uvedená kontrola zoznamu pripravovaných súborov. Tento záznam neuvádza nový experiment.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”can you prepare repo for pushing on github like gitignore and stuff, add dataset to gitignore (its forbiden), my teamates already have access”

Záznam 5 – Rozhodnutie o rozsahu projektu

Účel a zadanie. Rozhodnúť poradie monolingválnej a medzijazykovej časti a prepojiť plán s projektovým zadaním.

Nástroj a model. Claude Code, hlavný model podľa pôvodného logu Opus 5.5.

Použitý výstup. Odporúčaná bola monolingválna úloha ako hlavný vývojový cyklus a súbežné vyhodnocovanie medzijazykovej úlohy, keďže obe zdieľajú pipeline a uložené reprezentácie. Agent zhrnul požiadavky zadania a založil dokumentáciu použitia AI. Nešlo o meranie prínosu konkrétnej metódy.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”can i start with Monolingual and if there will be no complications move to Crosslingual or its just better to start Crosslingual right away”; ”own system, uploaded assigment in root folder”

Záznam 6 – Termíny a plán

Účel a zadanie. Zaznamenať používateľom uvedené termíny prvej etapy 25. októbra a druhej etapy 6. decembra.

Nástroj a model. Claude Code, hlavný model podľa pôvodného logu Opus 5.5.

Použitý výstup. Termíny boli doplnené do `CLAUDE.md`; agent navrhol harmonogram prvej etapy, literatúru a rozdelenie tímových rolí. Záznam nepredstavuje potvrdenie, že sa navrhnuté rozdelenie rolí skutočne prijalo alebo že sa úlohy dokončili.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”1. stage Oct 25th, 2. stage Dec 6th”

Záznam 7 – Husté vyhľadávanie bez dotrénovania

Účel a zadanie. Pripraviť multilingual-E5-large ako druhý baseline. Samostatný používateľský prompt nebol pri tomto zázname zachovaný; pôvodný log obsahuje opis delegovaného zadania.

Nástroj a model. Claude Code, hlavný model podľa úvodu Opus 5.5; worker Sonnet, následne judge agent.

Činnosť a použité výstupy. Worker nainštaloval PyTorch pre CUDA 12.8, pripravil fp16 enkodér s predponami `query:` a `passage:`, limitom 512 tokenov, diskovou cache a maticovým vyhľadávaním. Doplnil `src/retrieval/dense.py`, `scripts/run_dense.py`, konfigurácie a testy. Na dev porovnal originál, angličtinu a ich spojenie; pre každý track vybral variant a až potom vykonal testovací beh.

Overenie podľa logu. Judge uviedol PASS 5/5: preveril správne kolekcie a neprítomnosť úniku, podobnosť uložených a nanovo vypočítaných vektorov aspoň 0,9995, časové poradie výberu variantu na dev pred testom, reprodukovateľnosť a zhodu scorerov.

Výsledky. S@10 na dev: mono 0,862 pri spojení originálu a angličtiny; cross 0,591 pri angličtine. Test: mono 0,886 a cross 0,681; príslušný E5 organizátorov mal 0,859 a 0,637. Pri variante both bolo približne 11 % príspevkov dlhších než 512 tokenov.

Historické spresnenie. Pôvodný log pripisoval zisk najmä malajčine, thajčine, francúzštine, poľštine a arabčine a angličtinu s portugalčinou označil za približne nezmenené. Neskoršia kontrola reportu spresnila pokles angličtiny 0,818 → 0,814 a portugalčiny 0,808 → 0,802; zhodná zostala nemčina 0,872. Samotné porovnanie s organizátormi neurčuje príčinu rozdielov.

Záznam 8 – Silnejší analyzátor BM25 a medzijazykový textový variant

Účel a zadanie. Na používateľov pokyn spustiť dohodnuté experimenty a následne commitovať výsledky.

Nástroj a model. Claude Code, hlavný model podľa úvodu Opus 5.5; worker Sonnet a judge agent.

Činnosť a výstupy. Na dev sa porovnalo medzijazykové dense vyhľadávanie s originálom a angličtinou. Do BM25 pribudlo Snowball stemovanie cez PyStemmer, odstraňovanie stop slov

cez stopwordsiso a thajský tokenizer newmm z PyThaiNLP. Nasledovali dev ablácie a po výbere konfigurácie jeden testovací beh pre každú podúlohu.

Výsledky podľa logu. Dense cross na dev: both 0,533 oproti eng 0,591, preto variant both nešiel na test. BM25 mono dev: základná angličtina 0,685; so stemovaním 0,723; so stemovaním a stop slovami 0,773; both so stemovaním, stop slovami a thajskou segmentáciou 0,793. BM25 cross dev vzrástlo z 0,413 na 0,520. Finálne testovacie BM25 dosiahlo mono 0,868 a cross 0,623; organizátori 0,812 a 0,603.

Overenie a limity. Judge uviedol PASS 5/5: spätnú kompatibilitu, opravu odlišného formátu jazykového poľa iba v testovacích fact-checkoch, konzistenciu predikcií pri opakovanom overení, zhodu oficiálneho hodnotenia, neprítomnosť úniku a offline fungovanie analyzátora. Log uvádza, že základný regulárny výraz `\w+` nevhodne rozdeľoval thajské znamienka. Tvrdenia o vtedajšej kontrole sú prevzaté zo zdrojového záznamu.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> "yes run them and then commit"

Záznam 9 – Commit baseline riešení prvej etapy

Účel a zadanie. Pripraviť výsledky predchádzajúceho kroku na commit. Samostatný prompt nebol uvedený; tento krok nadväzuje na pokyn v zázname 8.

Nástroj a model. Claude Code podľa kontextu pôvodnej relácie; osobitný model pre tento krok nebol zaznamenaný.

Činnosť a overenie. Agent vykonal `git add` a pred commitom skontroloval zoznam pripravených súborov, či neobsahuje dátové súbory. Nie je tu zaznamenaný nový experiment ani nové skóre.

Relácia 2: 16. október 2026

Záznam 10 – Zber literatúry pre prvú etapu

Účel a zadanie. Zhromaždiť zdroje na základe používateľovho súhlasu s navrhnutým zberom literatúry.

Nástroj a model. Claude Code, hlavný model podľa pôvodného úvodu Opus 5.5. Iniciátor relácie 2 nie je v jej úvode výslovne identifikovaný.

Činnosť a použité výstupy. Agent čítal prehľad úlohy, prešiel index SemEval-2025 a jednotlivé stránky kľúčových článkov v ACL Anthology. Overoval názvy, autorov, strany a identifikátory, pretože niektoré odkazy v indexe boli posunuté. Vyhľadal aj pôvodné práce MultiClaim, Shaar, Kazemi, Vo a Lee a metodické zdroje GTR, mE5, BGE-M3 a PyThaiNLP. Vytvoril komentované tabuľky v `docs/literature.md` a záznamy v `docs/references.bib`.

Obmedzenia pôvodného výstupu. Niektoré bibliografické položky boli poskladané z overených polí namiesto oficiálneho exportu; vyskytovali sa skrátené zoznamy autorov alebo chýbajúci rozsah strán. Pôvodné stručné zhrnutia vychádzali z abstraktov a prehľadu, nenahrádzali čítanie článkov členmi tímu. Následný audit a obnova desiatich exportov sú zdokumentované v zázname 21.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> "yeah gather them" (reply to an offer to collect sources for the literature review)

Záznam 11 – Štatistiky dát a tabuľky reportu

Účel a zadanie. Vytvoriť skripty pre agregované štatistiky oboch oficiálnych splitov a tabuľky zostavené z uložených metrík a baseline predikcií organizátorov. Výstupy nemali obsahovať text príspevkov ani fact-checkov; loader sa nemal meniť a nič sa nemalo commitovať.

Nástroj a model. Claude Code subagent Claude Haiku 5.5 (`claude-haiku-5-5`) podľa pôvodného záznamu.

Použité výstupy. `scripts/data_stats.py`, `scripts/make_report_tables.py` a test zvýrazňovania najlepších výsledkov; agregáty `results/data_stats.{json,md}` a tabuľky `results/report_tables.md`.

Overenie podľa logu. Oba skripty sa spustili a pytest uviedol 43 úspešných testov, z toho štyri nové. Čísla overoval vyhodnocovací kód; výsledky organizátorov sa porovnali s publikovanými S@10, s maximálnym rozdielom 0,00004. Pôvodný záznam výslovne žiadal ľudské prečítanie štatistík pred ich použitím v reporte.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> "Write `scripts/data_stats.py` (aggregate-only dataset statistics for both official splits, written to `results/data_stats.{json,md}`), `scripts/make_report_tables.py` (main test table, per-language table, dev ablation table, built from `results/*/metrics.json` and the organizers' baseline predictions, written to `results/report_tables.md`), and a pytest for the bold-best logic. Do not commit; output must contain no post or fact-check text; reuse `src/data.py` without changing it."

Záznam 12 – Návrh slovenského reportu prvej etapy

Účel a zadanie. Dokončiť dostupné časti prvej etapy; používateľ zvolil slovenský jazyk a LaTeX.

Nástroj a model. Claude Code, Claude Opus 5.5; podľa záznamu tento návrh písal hlavný model bez subagenta.

Činnosť a použité výstupy. Vytvoril `report/stage1/main.tex` a tabuľky: úvod, prehľad literatúry, dáta, metodiku, baseline riešenia, výsledky s interpretáciou, plán druhej etapy a reprodukovateľnosť. Použil bibliografiu z repozitára a čísla z vygenerovaných tabuliek a štatistík. Neoverené vysvetlenia označil za hypotézy. Na doplnenie tímom zostali autori, URL repozitára a slovenská AI príloha.

Overenie podľa logu. Judge uviedol PASS 5/5 pre štatistiky a tabuľky z kroku 11, vrátane nulového podielu OCR-only príspevkov na teste, podielu hindských testovacích príspevkov 40,9 % a zhody tabuliek s metrikami. Toto nie je potvrdenie ľudského prečítania celého reportu. Neskoršie zistené interpretačné a citačné nepresnosti riešia záznamy 18, 21 a 22.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> "if everuthing clear for now can we finish things in stage 1"; report language and format chosen in a dialog: "Slovak, LaTeX".

Záznam 13 – Aktualizácia README

Účel a zadanie. Používateľ požiadal o aktualizáciu README, odkaz na report a následný commit a push.

Nástroj a model. Claude Code, hlavný model podľa úvodu pôvodného logu Opus 5.5.

Činnosť a použité výstupy. README dostalo prehľad dokumentov, aktuálnu výsledkovú tabuľku, príkazy na reprodukciu štyroch testovacích behov, očakávané S@10 a MRR@10 s toleranciami, pokyny na zostavenie reportu cez Tectonic alebo Overleaf a rozloženie repozitára.

Overenie podľa záznamu. Očakávané hodnoty boli prevzaté z uložených `metrics.json`, ktoré predtým overoval judge. Záznam nepopisuje nový reprodukčný beh; nezávislé zopakovanie štyroch konfigurácií nasledovalo v zázname 19.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”readme seems little bit update add like link to main.pdf or something also commit and push”

Záznam 14 – Pravidlá tímovej práce

Účel a zadanie. Vytvoriť `CONTRIBUTING.md` a doplniť stručnú verziu pravidiel s odkazom do README; používateľ požiadal aj o commit a push.

Nástroj a model. Claude Code, hlavný model podľa pôvodného logu Opus 5.5.

Použitý výstup. Pravidlá pokrývajú licenciu dát, experimentálny protokol, konvencie kódu a gitu, issues, povinnú evidenciu AI, report a termíny. Do README pribudol päťbodový súhrn. Text vychádzal z existujúcich konvencií a požiadaviek zadania.

Overenie. Samostatná skúška či výsledková metrika pri tomto zázname nebola uvedená. Ide o dokumentačný výstup.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”create contributing.md where all the rules will be then also add short version of team rules in readme with link to that md file then commit and push”

Záznam 15 – CI a pravidlá pre AI agentov

Účel a zadanie. Na žiadosť používateľa pripraviť CI a pravidlá, aby agent pri práci na issue postupoval v dohodnutom rozsahu a vyžadoval potrebné súhlasy.

Nástroj a model. Claude Code, hlavný model podľa pôvodného logu Opus 5.5.

Činnosť a výstupy. Vznikol `.github/workflows/ci.yml`: ochrana pred commitom dát a súborov nad 5 MB, pytest na Pythone 3.13 s CPU PyTorch a verejnou vzorkou a podmienené zostavenie reportu cez Tectonic s kontrolou nedefinovaných citácií. Do `CLAUDE.md` pribudli pravidlá rozsahu práce, zakázaných krokov, oprávnení, pravdivého vykazovania a AI logu. Používateľský `AGENTS.md` na ne odkazuje.

Overenie podľa logu. YAML sa načítal; dátový guard bol vyskúšaný na repozitári aj syntetických názvoch. Simulácia CI v čistom prostredí s ukrytou GPU dala 42 úspešných testov a jedno preskočenie GPU testu. Prvý pokus bez PyTorch odhalil chýbajúcu závislosť, preto sa doplnil CPU PyTorch. Kontrola citácií prebehla nad logom lokálneho zostavenia.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”also do you think its worth to create CI workflof? if so could you create one”; ”can you edit claude.md so when some teamate will type like ’clone this repo and help with issue #’ agent will go by the rules, dont do anything that shouldnt do or rogue …”

Relácia 3: 16. október 2026

Záznam 16 – Kontroly konfigurácií, vzorky, scorerov a predikcií

Iniciátor, nástroj a model. Roman Šafranko (`Mekr0t`) cez Claude Code; hlavný model Claude Opus 5.5, delegovaný subagent Claude Haiku 5.5 (`claude-haiku-5-5`) podľa pôvodného záznamu.

Účel a zadanie. Doplniť pevné regresné výsledky BM25 na verejnej vzorke, kontroly všetkých YAML konfigurácií, zhodu scorerov na skonštruovaných dátach, runtime kontrolu kolekcií a lokálne kontroly uložených oficiálnych predikcií. Výpočtové ani dátové závislosti nemali znemožniť CI bez datasetu či CUDA.

Použité výstupy. `src/checks.py` kontroluje presnú množinu príspevkov, aspoň desať rôznych identifikátorov a príslušnosť každej predikcie do správnej kolekcie. Zavolali ho oba oficiálne runnery. Pribudli testy vzorky, konfigurácií, scorerov a lokálnych predikcií. Povolené konfiguračné kľúče sa odvodzujú AST analýzou runnerov. Marker `needs_data` a premenná `SEMEVAL_OFFICIAL_DIR` umožňujú chýbajúce dáta výslovne zohľadniť.

Overenie podľa logu. Vtedajší stav s dátami: 248 passed, 57 skipped a 1 xfailed. Bez CUDA: 247 passed, 58 skipped a 1 xfailed. Bez oficiálnych dát sa preskočilo 22 lokálnych kontrol. Známy nesúlad názvu `bm25_sample.yaml` s `run_name` bol označený ako strict xfail. Opakovaný BM25 mono dev eng reprodukoval S@10 0,6847 a MRR 0,4942. Rozdiely v meracom JSON boli iba časovanie a ukončenia riadkov; súbor bol obnovený, aby sa referencie nemenili. Nový judge sa pre túto čiastkovú session nespustil a test split sa nepoužil.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> read `CLAUDE.md` (rules for AI agents) and `CONTRIBUTING.md`; add (1) a pinned BM25 sample test (S@10 0.9574 / 0.7794 for eng, 0.7021 / 0.5497 for orig) that does not write to `results/`; (2) a test over every `configs/*.yaml` (required keys, run_name equals filename stem, track/split/run_name consistency, dense vs BM25 keys, unknown keys derived from the runner code); (3) a toy parity test of `src/evaluate.py` against the copied official scorer in `scripts/score_official.py`; (4) a runtime helper that checks predictions are inside each post's pool, have at least 10 unique ids, and cover exactly the evaluated posts, called by both official runners before saving; (5) `needs_data` tests on saved official predictions that skip without the dataset. Do not commit; CI must pass without the dataset, CUDA or transformers.

Záznam 17 – Nadväzujúce opravy kontrol

Účel a zadanie. Dopracovať zistenia z kroku 16. Samostatný nový používateľský prompt v zázname nie je; ide o pokračovanie tej istej práce.

Nástroj a model. Hlavná relácia Claude Code s Claude Opus 5.5 podľa pôvodného logu.

Kontext a použité výstupy. Pôvodný judge uviedol PASS 5/5 a v CI simulácii bez modelového stacku, CUDA a datasetu 225 úspešných a 80 preskočených testov. V hlavnej relácii sa premenoval súbor na `bm25_sample_eng.yaml` a odstránil xfail. Kontrola predikcií sa presunula pred zápis metrík, aby neúspešný beh nezanechal platne vyzerajúci výsledok.

Overenie podľa logu. Celá sada mala 249 passed a 57 skipped; preskočenia boli kontroly nepoužiteľné pre daný typ konfigurácie. Vzorka reprodukovala S@10 0,9574. Tieto počty opisujú historický stav konfigurácií a lokálnych predikcií, nie univerzálny počet testov.

Relácia 4: 21. október 2026

Záznam 18 – Kontrola a lokálne opravy reportu prvej etapy

Iniciátor: Jakub Spišák (pripojený GitHub účet `jakub-spisak`).

Nástroj a model: OpenAI Codex desktop, agent založený na GPT-6. Presný identifikátor nasadeného modelu nebol v konverzácii sprístupnený.

Prompty (verné zhrnutie): používateľ požiadal o prezretie repozitára Mekr0t/FCCR a issues prvej etapy, následne o kontrolu issues #2 a #4 bez commitovania. Po posudku požiadal o lokálne zapracovanie navrhnutých zmien k issue #2 s jeho účtom ako committerom, s neskorším pushom na novú vetvu a vytvorením PR. Výslovne schválil prípravu lokálneho buildu a testov vrátane Tectonicu a CPU závislostí. Následne si vyžiadal vysvetlenie preskočených testov.

Kontrola a relevantný výstup:

- kontrola zdroja aj pôvodného desaťstranového PDF, bibliografických kľúčov a odkazov na tabuľky;
- 308 porovnaní vybraných výsledkových polí s uloženými metrikami a 99 porovnaní štatistických polí bez rozdielov na zobrazovanej presnosti;
- overenie hlavných tvrdení o TIFIN India, RACAI, QUST_NLP, UniBuc-AE, UWBa a Duluth v primárnych článkoch; efekt orig/eng pri QUST_NLP je podložený;
- identifikácia nesprávnych slovných záverov o E5 v angličtine a portugalčine, nepresného opisu finálneho UWBa a spojeného LoRA/prompt tuningu pri RACAI, chýbajúcich odkazov na tabuľky a menších nepresností o časoch a zhode scorerov.

Čo bolo zapracované: opravy do `report/stage1/main.tex` a regenerované `report/stage1/main.pdf`: presné porovnanie E5 po jazykoch, zúženie tvrdenia v abstrakte na E5 baseline, opravy prehľadu UWBa/RACAI a kontextu Shaar 2022, odkazy na všetkých šesť tabuliek, spresnenie časov BM25 a odchýlky S@10 pod 10^-4, počty orezaných monolingválnych príspevkov s uvedením splitu, zachovanie hypotéz ako hypotéz, drobné jazykové a typografické opravy. Meno Jakuba Spišáka bolo opravené podľa pripojeného profilu. Historické AI záznamy, tabuľky, metriky a implementácia pipeline neboli menené.

Overenie: Python 3.13.16, CPU PyTorch 2.11.0 a pripnuté testovacie balíky podľa CI; verejná vzorka v ignorovanom data/raw/sample. Pôvodný stav po nastavení lokálnych dočasných a PyThaiNLP cache adresárov: **226 passed, 59 skipped**. Preskočenia: 57 kontrol nepoužiteľných pre daný typ konfigurácie, jeden test modelu bez sentence-transformers a jeden test bez oficiálneho datasetu/predikcií. Pri prvom pokuse zlyhali zápisy do predvolených adresárov mimo workspace; po úprave premenných prostredia testy prešli bez zmeny kódu. Tectonic 0.17.0 vytvoril aktualizované PDF bez upozornení TeXu vrátane nedefinovaných citácií či referencií.

Záverečná kontrola: opakovaný pytest po úpravách: **226 passed, 59 skipped**. Všetkých desať strán aktualizovaného PDF bolo vizuálne skontrolovaných; šesť tabuliek má odkazy v texte a všetkých 23 použitých bibliografických kľúčov je definovaných. Tectonic nehlási pretečené riadky ani nedefinované citácie či referencie. Kontrola dátového guardu a git diff –check prešla. Túto kontrolu vykonal agent; ľudské review pred zlúčením ostáva na tíme.

Limity: nové experimenty na dev/test ani sťahovanie modelov sa nerobili. Originál Projektove_zadanie.pdf a súkromné historické prepisy neboli dostupné. V čase tejto staršej kontroly zostávali slovenská AI príloha a potvrdenia členov tímu predmetom issue #4; vtedajší zástupný text prílohy ešte nebol nahradený. Zapracovanie pripomienok samo osebe nepotvrdzuje úplné splnenie všetkých podmienok uzavretia issue #2.

Prepis: táto konverzácia v Codex desktop. Export prepisu nebol vytvorený; tím pri archivácii doplní jeho skutočné umiestnenie.

Relácia 5: 22.–24. október 2026

Záznam 19 – Reprodukcia štyroch konfigurácií z čistého klonu

Iniciátor, nástroj a model. Jakub Spišák (`jakub-spisak`), OpenAI Codex desktop. Pri zápise sa uvádzala rodina GPT-6 bez overeného presného identifikátora. Doplňujúce metadáta sú vysvetlené v úvode tejto prílohy.

Účel a zadanie. Použiť lokálne sprístupnené licencované dáta a dokončiť reprodukciu podľa issue #1. Používateľ výslovne schválil GPU závislosti aj stiahnutie modelu nad 1 GB a overenie všetkých štyroch konfigurácií.

Činnosť a použité výstupy. Z hlavného commitu `7c55503833ee5dab4ee1e601f2694fafffbce56d` vznikol oddelený čistý klon a vetva `s1-1-reproduce`. Kopírovali sa iba surové dáta od človeka; všetkých 28 súborov sa porovnalo pomocou SHA-256. Verejná vzorka sa stiahla nanovo. Prostredia, parsované dáta, modelová cache a embeddingy sa nepreberali zo staršieho checkoutu. Model `intfloat/multilingual-e5-large` mal revíziu `3d7cfbdacd47fdda877c5cd8a79fbcc4f2a574f3`.

Postup merania. Počas inštalácie GPU stacku prebehlo BM25 v samostatnom novom CPU prostredí s rovnakými pripnutými BM25 závislosťami. Dense a záverečné testy používali novú CUDA `.venv` na RTX 4060 Laptop. Reprodukčné YAML menili iba `run_name`, aby pôvodné metriky zostali zachované. Monolingválny dense beh bol 22. októbra prerušený a 24. októbra pokračoval zo svojich 196 608 uložených fact-check embeddingov; pred prerušením nevytvoril metriky ani predikcie. Žiadny dokončený experiment sa neopakoval na výber variantu.

Výsledky a overenie. Úvodná CPU sada: 226 passed a 59 skipped; reálny E5 GPU test: 1 passed. Záverečná CUDA sada: 259 passed a 65 preskočení nepoužiteľných konfiguračných kontrol. GPU test aj kontroly všetkých štyroch predikčných súborov prebehli. Obe BM25 metriky presne reprodukovali referencie. Dense výsledky boli v absolútnej tolerancii ±0,005; všetky štyri súbory prešli kontrolou oficiálnej logiky s výsledkom AGREE. Agregáty, plná presnosť, prostredie a časy sú uložené v reprodukčných výsledkoch.

Dokumentácia a publikovanie. README bolo spresnené pre Windows, studenú cache a premenlivé počty testov. Používateľ 24. októbra požiadal, aby push a PR vykonal sám; agent pripravil lokálny commit a texty. Autor aj committer sa porovnali s pripojeným profilom Jakuba. Táto tímová reprodukcia nepreukazuje samostatný bonus za reprodukciu osobou mimo tímu.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> inspect issue #1; use the supplied local path to the licensed SemEval-2025 Task 7 release and complete the issue. After being asked about the GPU dependencies and >1 GB model download, the user explicitly approved: "Áno, over všetky štyri konfigurácie".

Relácia 6: 24. október 2026

Záznam 20 – README pre chýbajúci Python 3.13

Iniciátor, nástroj a model. Roman Šafranko (`Mekr0t`), Claude Code; podľa pôvodného logu hlavný Claude Opus 5.5 a worker Claude Haiku.

Účel a zadanie. Skontrolovať Jakubov PR #17 a po jeho zlúčení človekom doplniť návod pre chybu Python launchera.

Činnosť a výstup. Agent prešiel diff a CI PR #17, overil jedinú zmenu parametra `run_name` v reprodukčných konfiguráciách a neprítomnosť textu datasetu. PR nezlučoval. Na novej vetve doplnil do README postup pre chybu `No suitable Python runtime found`: doinštalovať Python 3.13, otvoriť nový terminál a znova overiť runtime launcherom.

Overenie podľa pôvodného záznamu. Pytest uviedol 277 passed a 65 skipped. Diff bol obmedzený na README a AI log. Rozdiel oproti Jakubovým počtom testov môže súvisieť s lokálne dostupnými predikčnými súbormi; samotný počet nie je pevnou vlastnosťou projektu.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”there should be some pull request from jakub, can you check it”; after PR #17 was merged: ”merged, now do the readme fix”.

Relácia 7: 25. október 2026

Záznam 21 – Kontrola primárnych článkov a bibliografie

Iniciátor, nástroj a model. Jakub Spišák (`jakub-spisak`), Codex desktop, pôvodne zaznamenaná rodina GPT-6; PDF skill, web a ACL Anthology, Python/pypdf, Poppler a Tectonic 0.17.0 na overenie.

Účel a zadanie. Stiahnuť aktuálne zmeny a riešiť zostávajúce časti prvej etapy v poradí #3 → #4 → #2, po jednej PR, s nadväzujúcimi lokálnymi zmenami a commitmi pod používateľovým účtom. Pushy a PR zostali na človeku.

Činnosť a výstupy. Po udelení sieťového oprávnenia sa `main` aktualizoval iba fast-forwardom na `2c4323ddf1420693447436d38a62daaf3b73f1a3` a vznikla vetva `s1-3-literature-check`. Skontrolované boli relevantné metodické a výsledkové časti Peng, MultiClaim, TIFIN, RACAI, UniBuc-AE a QUST_NLP; doplnkovo UWBa, Duluth, fact check AI a Shaar 2022. Opravili sa súhrny, pôvod skóre, finálne konfigurácie oproti pokusným variantom a neoverené zovšeobecnenia o hardvéri. Desať bibliografických položiek sa obnovilo z oficiálneho exportu bez zmeny citačných kľúčov. Pribudli zdrojové lokácie a otázky na ľudskú kontrolu.

Overenie. Úvodná aj konečná sada: 259 passed a 65 nepoužiteľných konfiguračných preskočení; konečný beh trval 15,33 s a zahŕňal reálny model/GPU aj lokálne predikcie. Tectonic použil cache, všetkých 24 citácií sa vyriešilo bez neznámych znakov a všetkých 11 strán sa vizuálne skontrolovalo. Nové retrieval experimenty, inštalácie ani sťahovanie modelov neprebehli.

Ľudská kontrola. Používateľ na otázku o povinnom čítaní odpovedal: „Zatiaľ nepotvrdzujem, prejdem podklady.“ Automatizovaný audit nebol vydávaný za ľudské čítanie. Vtedajší pripravený návrh preto používal Refs #3; neskorší PR môže mať Closes #3 s podmienkou ľudského potvrdenia pred merge. Pôvodná AI príloha a ostatné reportové opravy zostali pre nasledujúce issues.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> pull the newest repository changes; work through stage-1 issues #3 → #4 → #2 with a separate PR after each; keep subsequent local work based on the preceding changes; ask for required permissions and use the human’s account for commits. The human will perform pushes and create PRs.

Záznam 22 – Tri rozpory v reporte nahlásené človekom

Iniciátor, nástroj a model. Jakub Spišák, 25. októbra 2026; OpenAI Codex desktop, pôvodne zapísaná rodina GPT-6.

Účel a zadanie. Zapracovať tri konkrétne pripomienky používateľa: porovnanie iba so zodpovedajúcim E5 a s crosslingválnym GTR organizátorov; portugalčinu a potom angličtinu ako najslabšie jazyky vlastného E5; výslovné zníženie skóre v angličtine a portugalčine oproti organizátorom.

Použitý výstup. Zmenené boli tri pasáže `main.tex`, odstránené nedoložené tvrdenie o kvalite dát a príčinné prisudzovanie rozdielov textovému variantu. Odsek s porovnaním jazykov zostal na jednej strane. Zdroj aj PDF boli aktualizované a zmena sa zapísala do logu.

Overenie. Poradie jazykov sa porovnalo s uloženými dense metrikami a hodnoty organizátorov s reportovými tabuľkami. Tectonic zostavil PDF, citácie a znaky boli v poriadku a dotknuté strany sa vizuálne skontrolovali. Kód a metriky sa nemenili. Čítanie článkov pre #3 tým nebolo automaticky potvrdené.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> correct three remaining PDF statements: specify that our E5 beats the organizers' E5 in both tracks but not their crosslingual GTR; identify Portuguese, then English, as the lowest-scoring languages without an unsupported data-quality claim; state the unchanged German score and the English/Portuguese decreases explicitly.

Záznam 23 – Vyriešenie konfliktu PR #19 s main

Iniciátor, nástroj a model. Jakub Spišák, 25. októbra 2026; OpenAI Codex desktop, pôvodne zapísaná rodina GPT-6.

Účel a zadanie. Pozrieť a lokálne vyriešiť konflikt v PR; GitHub push a merge zostali na človeku.

Činnosť a použitý výstup. Po udelení prístupu na sieť sa stiahli aktuálne referencie a do vetvy #3 sa lokálne zlúčilo `origin/main`. Obe vetvy doplnili rovnaké miesto AI logu a použili číslo 20. Romanov úplný záznam sa zachoval bez zmien; iba naše hlavičky boli prečíslované na reláciu 7 a záznamy 21-22. Prevzal sa aj nový návod v README. Faktický obsah pôvodných záznamov sa nemenil.

Overenie. Prichádzajúci historický prefix a README sa porovnali s main; naše záznamy sa overili po spätnom zrušení samotného prečíslovania. Nezostali konfliktové značky. Report/PDF, kód, konfigurácie a metriky boli identické so stavom pred merge. Testy: 259 passed a 65 nepoužiteľných preskočení, 14,90 s. Ľudské čítanie pre #3 ostalo nepotvrdené.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> inspect and resolve the conflict in the PR. The human continues to handle pushes and GitHub PR actions.

Relácia 8: 25. október 2026

Záznam 24 – Doplnenie a slovenský preklad AI prílohy

Iniciátor, nástroj a model. Jakub Spišák, 25. októbra 2026; OpenAI Codex desktop. V lokálnych metadátach tejto konverzácie bolo overené označenie `gpt-6.1-sol`. Označenia starších Claude modelov sú prevzaté zo zdrojového logu a neboli nezávisle overované.

Účel a zadanie. Pokračovať issue #4 a pripraviť povinnú AI prílohu nadväzujúcu na lokálny stav #3. Na základe skoršieho pokynu mal agent žiadať potrebné povolenia, používať používateľovu commit identitu a nechať push a PR na človeku.

Činnosť a použité výstupy. Vznikla vetva `s1-4-ai-appendix` z commitu `bd3858109af6c3e2a4fae2d4f6dcc1714449819c`. Do primárneho logu sa bez úprav skopíroval už existujúci záznam 18 zo samostatného checkoutu #2 a doplnil sa tento záznam. Slovenská príloha pokrýva záznamy 1-24, zachované prompty, účely, výstupy, overenie a obmedzenia; nahrádza pôvodný zástupný text v reporte. Samostatný prehľad sleduje pokrytie AI použitia, skutočné lokácie prepisov a potvrdenia členov tímu.

Overenie a stav. Úvodná sada prešla s 259 passed a 65 nepoužiteľnými preskočeniami za 21,02 s. Záverečná sada: 259 passed a 65 nepoužiteľných preskočení za 33,06 s vrátane GPU/modelového testu a kontrol štyroch predikčných súborov. Overilo sa všetkých 24 číslovaných záznamov a 21 záznamov so zachovaným poľom promptu; historické medzery pri 7, 9 a 17 sú výslovne označené. Všetkých 24 citácií sa vyriešilo bez chýbajúcich znakov. PDF bolo zostavené z cache a vizuálne skontrolované; pôvodný zástupný text prílohy bol nahradený. Dve drobné typografické upozornenia v hlavnom texte zostali pre finálnu kontrolu reportu #2. Nové modely ani balíky sa neinštalovali a retrieval experimenty neprebehli.

Prepisy a ľudské údaje. Overila sa existencia lokálneho Codex JSONL súboru a zhoda ID s týmto chatom; čítali sa iba metadáta relácie/turnov, nie obsah správ. Ide o živý aplikačný súbor, nie overený nemenný export. Pôvodná Claude cesta sa na tomto počítači nenašla; jej dostupnosť u vlastníka nie je potvrdená. Agent si vyžiadal skutočné použitie AI a potvrdenie úplnosti za každého člena aj stav archívu. Jakub následne oznámil, že zvyšní členovia AI nepoužívali. Toto sprostredkované oznámenie je zaznamenané pre Viktora Hančovského a Benjamína Konkoľa; Jakub a Roman už majú zdokumentované použitie. Potvrdenie úplnosti Jakubovej a Romanovej časti a finálneho archívu zostáva otvorené.

Znenie promptu alebo zhrnutia zachované v primárnom logu.

> ”dobre, vieme sa venovat dalšej časti? issue #4”. Existing instructions: work in order #3 → #4 → #2, base later local branches on earlier changes, ask for required permissions, commit as Jakub, and leave push/PR actions to the human.

Relácia 9: 25. október 2026

Záznam 25 – Záverečná kontrola reportu prvej etapy

Iniciátor, nástroj a model. Jakub Spišák, 25. októbra 2026; Codex desktop. Pri predchádzajúcej kontrole metadát tohto chatu bolo zaznamenané označenie `gpt-6.1-sol`. Overenie používalo Python/pypdf, Poppler, Tectonic 0.17.0 a primárne články.

Prompt a účel. Používateľ uviedol: „ja ten PR spravím potom... môžeme pokračovať na issue #2...“. Pokyn nadväzoval na postup #3 → #4 → #2, lokálne commity pod jeho účtom a publikovanie človekom. Následne poskytol skutočnú lokálnu cestu k pôvodnému projektovému zadaniu.

Činnosť a použité výstupy. Na vetve `s1-2-final-report-review`, založenej na lokálnom stave #4, sa skontrolovalo trojstranové zadanie a jeho kritériá prvej etapy. Zapracovali sa iba zostávajúce relevantné opravy zo staršej samostatnej kontroly #2; novšie opravy literatúry a AI príloha zostali zachované. Opravilo sa meno autora, odkazy na všetkých šesť tabuliek, rozsah časov BM25, tolerancia publikovaných skóre, opisy OCR a dĺžok textu a presné počty orezaných príspevkov. Spresnil sa výber modelov v MultiClaim, rankSVM v práci Shaar 2020, odlíšenie pôvodných výsledkov od reprodukcie a plán získavania negatívnych príkladov iba pre trénovacie príspevky. Neoverené vysvetlenia ostali hypotézami. Upravili sa popisy tabuliek a názov modelu MPNet. Pribudol prehľad kontroly v `docs/stage1_report_review.md`, tento záznam a aktualizované PDF.

Overenie. Úvodné testy: 259 passed a 65 preskočení za 17,87 s; záverečné: 259 passed a 65 preskočení za 17,13 s. Všetky preskočenia boli kontroly nepoužiteľné pre daný typ konfigurácie; reálny GPU/modelový test aj kontroly štyroch predikcií prebehli. Automatizovaný audit porovnal 668 polí: 595 číselných hodnôt a 73 zámerne chýbajúcich polí bez rozdielu. Kontrola zahŕňala všetky tabuľky, citácie, relevantné tvrdenia o zdrojoch a kritériá zadania. PDF sa zostavilo z cache, vyriešilo všetkých 24 citácií a bolo vizuálne skontrolované. Pôvodné dve typografické upozornenia hlavného textu boli odstránené.

Limity a ľudská kontrola. Čítanie článkov pre #3 a úplnosť Jakubových/Romanových AI záznamov a finálneho archívu pre #4 ešte neboli potvrdené. Technická kontrola nenahrádza tímové čítanie celej správy a review. Historický primárny log, kód, konfigurácie, výsledky aj bibliografia zostali nezmenené. Dataset ani zadanie sa nepridávajú do Gitu; nové retrieval experimenty, sťahovanie modelov ani inštalácie neprebehli. Push, PR, komentáre a merge vykoná človek.